🏆 Trabajo Práctico Integrador: Decision Intelligence Capstone

Modelado Predictivo, Inferencia Causal y Sistemas de Decisión en Producción

Cátedra: Estadística Aplicada y Modelos de Regresión (EAyMR 2026)
Institución: Pontificia Universidad Católica Argentina (UCA) — Facultad de Ingeniería y Ciencias Agrarias
Carreras: Licenciatura en Ciencia de Datos / Ingeniería en Inteligencia Artificial (2º Año – 2º Semestre)
Profesor Titular / Responsable: Prof. Ivan Gonzalo Vilaboa
Fecha Límite de Entrega y Defensa Oral: Miércoles 18 de Noviembre de 2026 (Semana 13)
Modalidad: Grupal (equipos de 3 a 4 integrantes) con asignación formal de roles de ingeniería Scrum.
Ponderación Oficial en Cursada: 3.0 Puntos (30% de la nota final de cursada). Evaluado sobre una escala rúbrica de 100 puntos.
Entregables: Repositorio GitHub modular, Notebook Maestro Reproducible (`TP_Integrador_Final.ipynb`), Bitácora de Ingeniería (`BITACORA.md`), Aplicación Web Desplegada en Producción (Deploy interactivo en vivo) y Defensa Oral con Diapositivas Ejecutivas.

---

1. Fundamentación y Propósito del Proyecto

En el ejercicio profesional contemporáneo de la Ciencia de Datos y la Ingeniería en Inteligencia Artificial, el mayor desafío de una organización no radica simplemente en optimizar una métrica de ajuste (R^2 o AUC-ROC) en una partición estática de prueba. El desafío crítico reside en responder dos preguntas fundamentales de negocio y política:

1. **Predicción Observacional:** Dado lo que observamos del mundo bajo condiciones estables, ¿qué es probable que suceda en el futuro? ($P(Y \mid X)$)
2. **Intervención y Decisión Causal:** Si decidimos modificar activamente una variable del sistema mediante una política, incentivo o tratamiento, ¿qué impacto provocará realmente dicha acción y cuál es el valor esperado del cambio? ($P(Y \mid do(T = t))$)

Confundir la capacidad predictiva de un algoritmo con su capacidad para guiar decisiones de intervención suele conducir a **políticas corporativas o públicas desastrosas**: optimizar palancas basadas en correlaciones espurias, acondicionar variables colisionadoras (colliders) que introducen sesgos artificiales de selección o ignorar factores de confusión ocultos.

El **Trabajo Práctico Integrador (TPI)** constituye el proyecto cumbre (Capstone Project) de la asignatura. Su objetivo es que cada equipo asuma el rol de una **Unidad Especializada de Inteligencia de Decisiones y Modelado Avanzado**, desarrollando una solución analítica integral que articule:

- El **rigor analítico de la inferencia estadística clásica y experimental** (contrastes de hipótesis, potencia muestral, diagnósticos de Gauss-Markov y ANOVA con verificación estricta de supuestos).
- La **capacidad predictiva y de reducción dimensional del Machine Learning moderno** (PCA libre de fuga de datos, regularización Ridge/Lasso, Naive Bayes, Árboles CART podados y Ensambles Random Forest con validación cruzada y calibración de probabilidades).
- La **lucidez metodológica de la Inferencia Causal y el Causal ML** (formalización de Grafos Acíclicos Dirigidos —DAGs— en la Unidad 6, criterio Backdoor con `DoWhy`, estimación de efectos heterogéneos CATE mediante Double Machine Learning en `EconML` y pruebas de refutación estocástica).
- La **ingeniería de software y trabajo en equipo ágil** (organización de equipos bajo un marco de trabajo Scrum con roles técnicos definidos, puerta determinística de calidad Quality Gate, registro vivo en la `BITACORA.md` y puesta en producción de una aplicación web interactiva desplegada).

---

2. Marco de Calificación y Cronograma de Entregas

El régimen de evaluación de la asignatura se articula armónicamente para totalizar los **10.0 puntos** de la cursada:

- **1. Trabajos Prácticos de Cursada (3.0 Pts / 30%):** 6 TPs evaluados a 0.5 pts cada uno, distribuidos en dos grandes entregas grupales:
  - Entrega 1 (Semana 6 - 30/09): TP 1 (Exploración y Probabilidad), TP 2 (Inferencia y ANOVA) y TP 3 (Regresión Lineal y PCA). Total: **1.5 pts**.
  - Entrega 2 (Semana 11 - 04/11): TP 4 (Regresión Logística y Naive Bayes), TP 5 (Árboles CART y Random Forest) y TP 6 (Inferencia Causal y DAGs). Total: **1.5 pts**.
- **2. Evaluación Parcial Presencial (4.0 Pts / 40%):** Examen individual teórico-práctico centrado en Unidades 2 y 3 (Semana 7).

- **3. Trabajo Práctico Integrador Capstone (3.0 Pts / 30%):** Evaluación integral sobre 100 puntos en la Rúbrica Oficial, escalada linealmente a los **3.0 puntos finales** ($\text{Nota en Cursada} = \frac{\text{Puntaje Rúbrica}}{100} \times 3.0$).

---

3. Dominio y Selección del Dataset

Cada equipo seleccionará un conjunto de datos tabular del mundo real con un volumen mínimo de $N \geq 1.500$ observaciones y al menos 10 variables explicativas (combinación de atributos continuos, discretos y categóricos).

> [!IMPORTANT] **Prohibición Estricta de Datasets de Juguete (Toy Datasets):** Queda terminantemente desestimado el uso de datasets triviales o ultra-estudiados con fines meramente pedagógicos como Iris, Titanic, Boston Housing, Wine Quality o Palmer Penguins. El proyecto exige lidiar con la fricción del dato real: valores ausentes no aleatorios, multicolinealidad estructural, colas pesadas y potenciales factores de confusión no observables.

Dominios de Aplicación Sugeridos

1. **Finanzas Cuantitativas, Crédito y Riesgo Sistémico:**
   - Pregunta Causal: ¿Cuál es el impacto causal de ofrecer una línea de refinanciación o reducción de tasa de interés (T) sobre la tasa de morosidad o retorno esperado (Y), controlando por nivel de ingreso, antigüedad laboral y scoring crediticio externo (Z)?
2. **Salud Digital, Epidemiología y Medicina de Precisión:**
   - Pregunta Causal: ¿Cuál es el efecto causal de un protocolo terapéutico o intervención intensiva de telemedicina (T) sobre los días de recuperación clínica o rehospitalización (Y), ajustando por comorbilidades basales, edad y biomarcadores (Z)?
3. **Economía Urbana, Real Estate y Sustentabilidad:**
   - Pregunta Causal: En la valuación hedónica de inmuebles (ej. dataset Properati enriquecido), ¿cuál es el efecto de la proximidad peatonal a estaciones de transporte masivo o infraestructura verde (T) sobre el valor del metro cuadrado (Y), aislando el estrato socioeconómico barrial y la densidad de edificación (Z)?
4. **Energía, Redes Inteligentes (Smart Grids) e Industria 4.0:**
   - Pregunta Causal: ¿Cuál es el impacto real de implementar tarifas dinámicas o programas de gestión de demanda pico (T) sobre el consumo energético

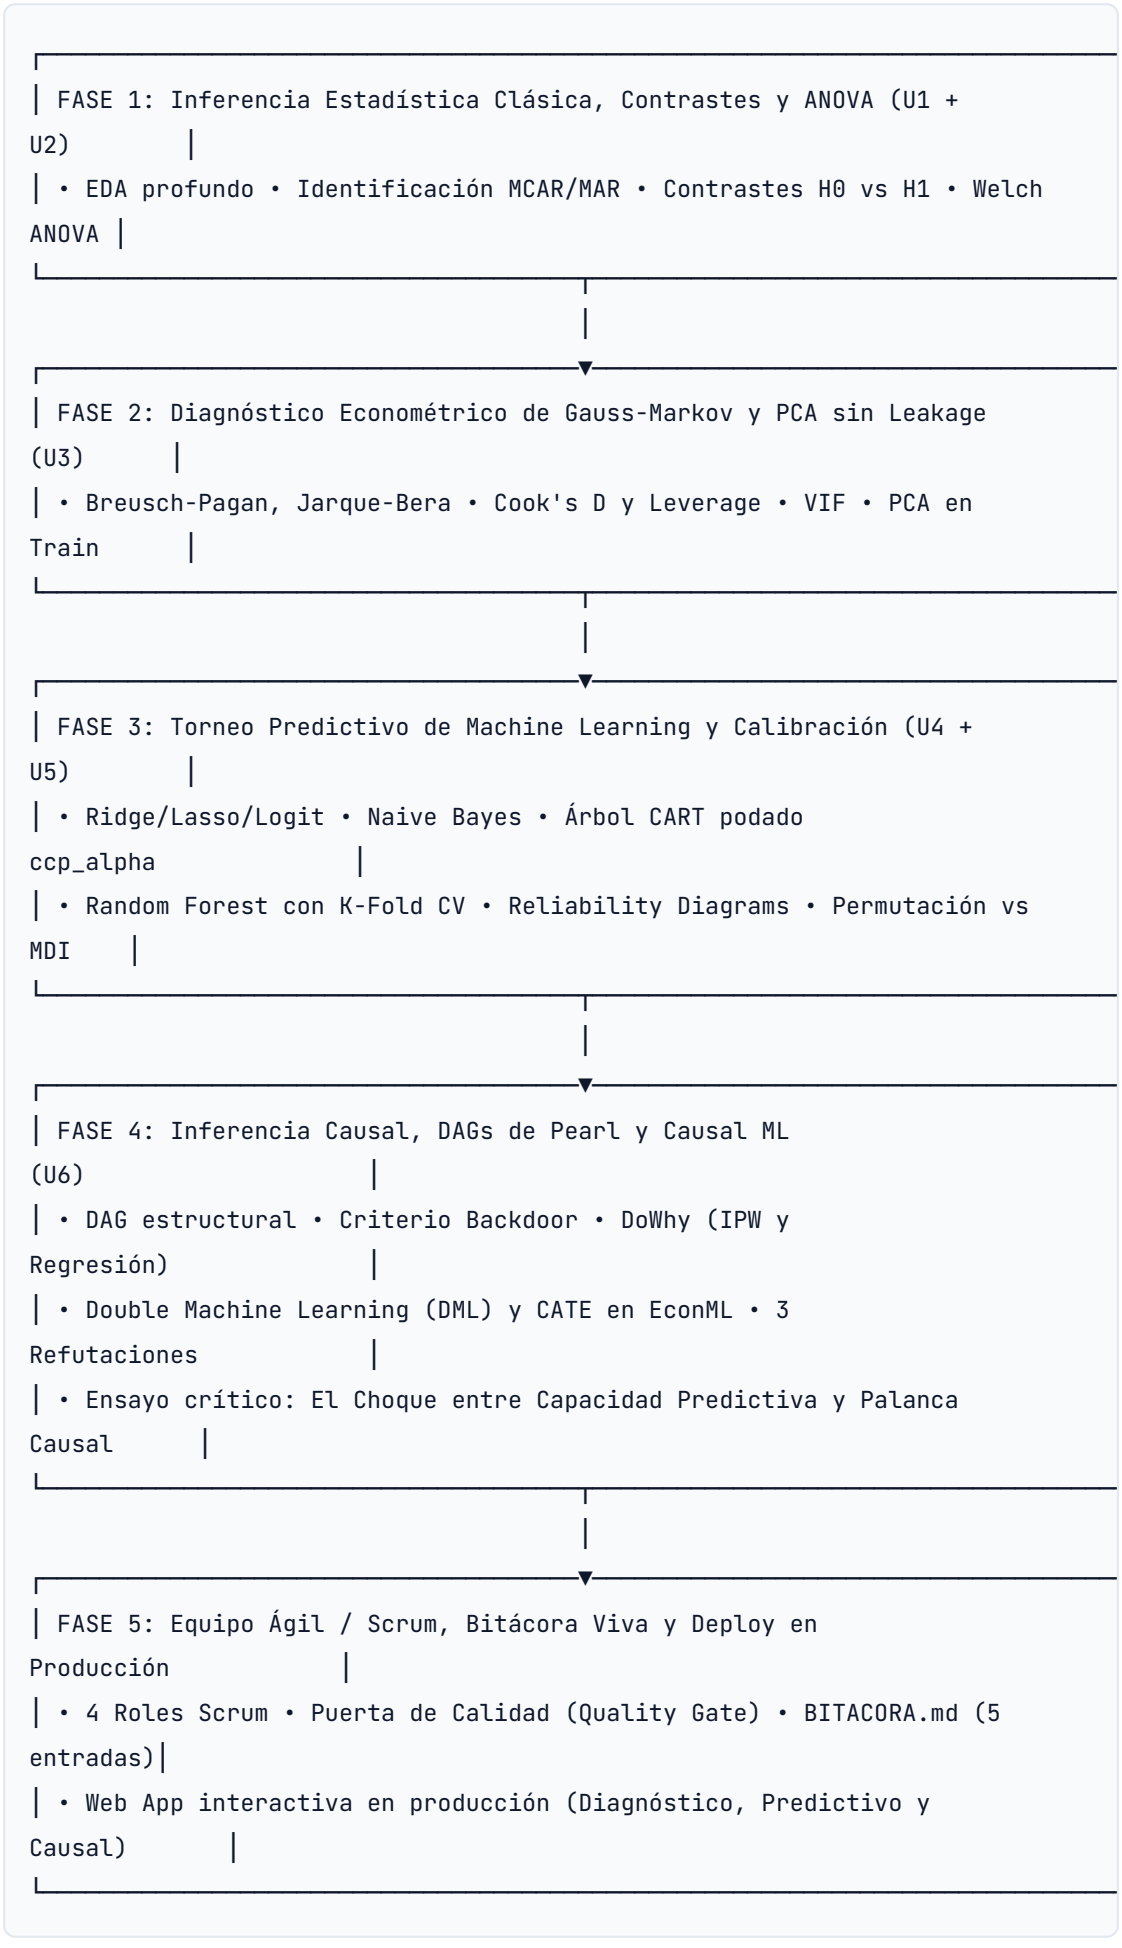
industrial horario (Y), diferenciando el efecto causal de las fluctuaciones climáticas y los calendarios de producción (Z)?

5. **E-Commerce, Plataformas y Growth Marketing:**
    - Pregunta Causal: ¿Qué incremento causal en el Valor de Vida del Cliente (CLV) o retención (Y) genera la asignación de un nuevo motor de recomendaciones o cupón de bienvenida (T), distinguiendo la auto-selección de usuarios recurrentes frente al efecto genuino de la política (Z)?

---

4. Arquitectura del Proyecto: Las 5 Fases de Ejecución

El ciclo de desarrollo se estructura en cinco fases progresivas e incrementales:


FASE 1: Inferencia Estadística Clásica, Contrastes y ANOVA (U1 + U2)
• EDA profundo • Identificación MCAR/MAR • Contrastes H0 vs H1 • Welch ANOVA
FASE 2: Diagnóstico Econométrico de Gauss-Markov y PCA sin Leakage (U3)
• Breusch-Pagan, Jarque-Bera • Cook's D y Leverage • VIF • PCA en Train
FASE 3: Torneo Predictivo de Machine Learning y Calibración (U4 + U5)
• Ridge/Lasso/Logit • Naive Bayes • Árbol CART podado ccp_alpha
• Random Forest con K-Fold CV • Reliability Diagrams • Permutación vs MDI
FASE 4: Inferencia Causal, DAGs de Pearl y Causal ML (U6)
• DAG estructural • Criterio Backdoor • DoWhy (IPW y Regresión)
• Double Machine Learning (DML) y CATE en EconML • 3 Refutaciones
• Ensayo crítico: El Choque entre Capacidad Predictiva y Palanca Causal
FASE 5: Equipo Ágil / Scrum, Bitácora Viva y Deploy en Producción
• 4 Roles Scrum • Puerta de Calidad (Quality Gate) • BITACORA.md (5 entradas)
• Web App interactiva en producción (Diagnóstico, Predictivo y Causal)

🔬 FASE 1: Inferencia Estadística Clásica, Diagnósticos y ANOVA

(Articulación directa con Unidades 1 y 2)

El equipo no comenzará entrenando modelos de caja negra. Primero debe demostrar comprensión inferencial de los datos poblacionales y muestrales:

1. **Ingeniería Exploratoria y Caracterización de Distribuciones:**
   - Análisis univariado y bivariado con visualizaciones densas (distribuciones empíricas KDE, boxplots, matrices de correlación Spearman y Pearson).
   - Identificación del mecanismo de pérdida de datos: clasificar variables faltantes como MCAR (Missing Completely at Random), MAR (Missing at Random) o MNAR (Missing Not at Random), justificando matemáticamente la estrategia de imputación seleccionada.

2. **Formulación y Ejecución de Contrastes de Hipótesis:**
   - Plantear **al menos dos pruebas de hipótesis formales** (H_0 frente a H_1) con relevancia directa para el negocio o la ciencia del problema.
   - Seleccionar y justificar el estadístico de prueba (paramétrico: test t de Student para muestras independientes/pareadas, test F; no paramétrico: Mann-Whitney U o Wilcoxon).
   - Fijar a priori el nivel de significancia α, reportar el p-valor exacto, el intervalo de confianza del 95% para la diferencia y la **magnitud del efecto** (Cohen's d o similar).

3. **Análisis de Varianza (ANOVA) y Diagnóstico de Supuestos:**
   - Diseñar un ANOVA de un factor para evaluar si el valor esperado de la variable de interés varía entre 3 o más subgrupos poblacionales significativos.
   - **El Desafío Metodológico (Evitar el Spoonfeeding):**
     - ¿Qué ocurre con el test de Shapiro-Wilk cuando el tamaño muestral es grande ($N \geq 1.500$)? Alerta: En muestras masivas, casi cualquier prueba formal de normalidad rechazará H_0 ante perturbaciones microscópicas irrelevantes para el Teorema Central del Límite. El equipo debe evaluar el supuesto mediante análisis de asimetría (skewness $\in [-1, 1]$), curtosis y gráficos Q-Q Plot.
     - Evaluar la homogeneidad de varianzas mediante el test de Levene. En caso de heterocedasticidad demostrada, ¿qué alternativa aplican? Demostrar la aplicación de **Welch's ANOVA** o la prueba no paramétrica de **Kruskal-Wallis**.
     - Si se rechaza H_0, aplicar comparaciones múltiples post-hoc controlando la tasa de error por familia (Tukey HSD vs corrección de Bonferroni).

📐 FASE 2: Diagnóstico de Gauss-Markov, Puntos Influyentes y Reducción PCA

(Articulación directa con Unidad 3)

1. **Ajuste del Modelo Lineal Clásico de Referencia:**
   - Estimar un modelo de regresión lineal múltiple por Mínimos Cuadrados Ordinarios (MCO):

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \varepsilon$$

   - Reportar R^2, R^2 ajustado, estadístico F global y significancia individual de los coeficientes (t-test).

2. **Auditoría Exhaustiva de Supuestos de Gauss-Markov:**
   - **Homocedasticidad:** Gráfico de residuos frente a valores ajustados ($\hat{y}$) y ejecución formal del test de Breusch-Pagan o White (p-valor e interpretación).
   - **Normalidad de Residuos:** Gráficos Q-Q Plot y test de Jarque-Bera.
   - **Independencia de Errores:** En presencia de ordenamiento temporal o espacial, verificar autocorrelación mediante el estadístico de Durbin-Watson.

3. **Detección y Tratamiento de Observaciones Extremas:**
   - Descomponer analíticamente el impacto de las observaciones atípicas:
     - Residuos estudentizados externamente: detección de outliers de respuesta ($|r_i| > 3$).
     - Apalancamiento (Leverage h_{ii}): identificar observaciones extremas en el espacio de covariables ($h_{ii} > \frac{2(p+1)}{n}$).
     - Puntos Influyentes: calcular la **Distancia de Cook (D_i)**:

$$D_i = \frac{e_i^2}{(p+1)\,\mathrm{MSE}} \left[\frac{h_{ii}}{(1-h_{ii})^2} \right]$$

       Identificar observaciones con $D_i > \frac{4}{n}$ o $D_i > 0.5$. Fundamentar si corresponden a errores de medición o a casos reales que ameriten regresión robusta (Huber / RANSAC).

4. **Diagnóstico de Multicolinealidad:**
   - Calcular los Factores de Inflación de Varianza (**VIF**):

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

   - Identificar predictores con $\mathrm{VIF} > 5$ o $\mathrm{VIF} > 10$. Justificar la estrategia de resolución (eliminación de variables, combinación funcional o regularización Ridge).

5. **Reducción de Dimensionalidad con PCA (Sin Data Leakage):**
   - **Regla Estricta:** Estandarizar variables numéricas y computar la descomposición espectral o SVD **únicamente sobre el subconjunto de entrenamiento (Train)**. Aplicar la matriz de rotación sobre Test de manera ciega.
   - Graficar el Scree Plot y la curva de varianza explicada acumulada. Justificar la cantidad de componentes retenidos mediante la regla del codo o el criterio de Kaiser ($\lambda_k > 1$).
   - Inspeccionar la matriz de cargas (loadings / autovectores): ¿Qué interpretación conceptual de negocio adquieren los primeros dos componentes principales?

🌲 FASE 3: Torneo de Modelos Predictivos, Machine Learning y Calibración

(Articulación directa con Unidades 4 y 5)

El equipo implementará un torneo riguroso entre cuatro familias algorítmicas bajo un esquema de partición estricto: **Train (80%) y Test (20%)**, con **Validación Cruzada K-Fold (5 pliegues)** en Train. En caso de clasificación binaria/multiclase, la partición debe ser `StratifiedKFold`.

1. **Familia 1: Modelos Lineales Regularizados / Clasificación Logística:**
   - Si el problema es de regresión: ajustar y optimizar modelos **Ridge (L_2)**, **Lasso (L_1)** y **ElasticNet**. Comparar la penalización sobre los coeficientes.
   - Si el problema es de clasificación: ajustar **Regresión Logística multinivel o regularizada**. Extraer e interpretar los **Odds Ratios** ($\text{OR} = e^{\beta_j}$) con intervalos de confianza al 95%.

2. **Familia 2: Clasificador Probabilístico Naive Bayes:**
   - Implementar `GaussianNB`, `BernoulliNB` o `MultinomialNB` según la naturaleza de las características.
   - Evaluar la violación del supuesto de independencia condicional $P(X_1, \ldots, X_p \mid Y) = \prod P(X_i \mid Y)$ y analizar cómo afecta la calibración de las probabilidades finales predichas frente a la regresión logística.

3. **Familia 3: Árbol de Decisión Individual (CART) y Poda por Complejidad:**
   - Entrenar un árbol de decisión sin restricciones de profundidad para ilustrar el sobreajuste (overfitting) severo (comparar métricas de Train vs Test).
   - Implementar la **Poda por Complejidad de Costo (Cost-Complexity Pruning)**:

     $$R_\alpha(T) = R(T) + \alpha|T|$$

     Extraer el camino de valores de α con `cost_complexity_pruning_path` y determinar el α_{opt} mediante K-Fold Cross-Validation.

- Visualizar los primeros niveles del árbol podado e interpretar la regla de decisión en el nodo raíz.

4. **Familia 4: Ensamble Random Forest y Búsqueda de Hiperparámetros:**
   - Construir un ensamble `RandomForestRegressor` o `RandomForestClassifier`.
   - Ejecutar una optimización sistemática (`GridSearchCV` o `RandomizedSearchCV`) sobre: `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf` y `max_features` (`sqrt`, `log2`, fracción).
   - Reportar el error **Out-of-Bag (OOB)** y comparar su convergencia frente a la validación cruzada.

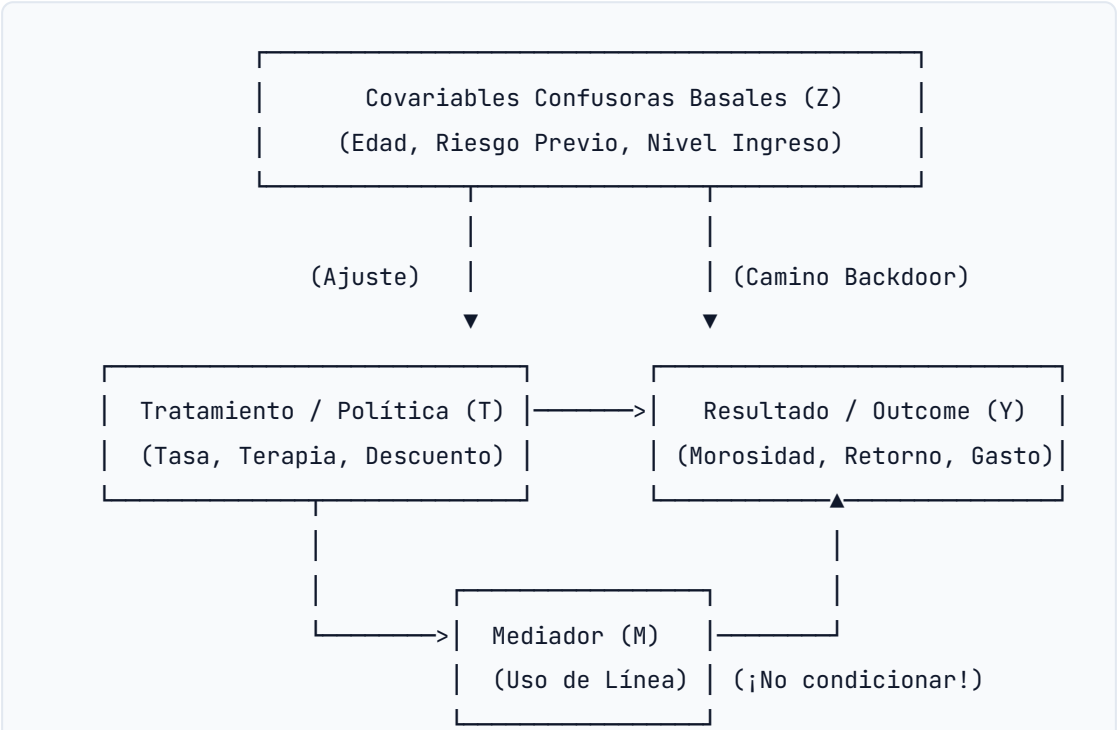
5. **Evaluación de Rendimiento en el Conjunto de Test:**
   - **Para Regresión:** Matriz comparativa con R^2, RMSE, MAE y MAPE.
   - **Para Clasificación:** Precision, Recall, F1-Score (macro y ponderado), Curva ROC y AUC-ROC, Curva Precision-Recall (PR-AUC) y Brier Score.
   - **Curvas de Calibración Probabilística (Reliability Diagrams):** Evaluar si las probabilidades estimadas por los modelos están bien calibradas frente a las frecuencias observadas.

6. **Explicabilidad: Choque entre MDI y Permutation Importance:**
   - Calcular la importancia de variables por impureza media (MDI / Gini Feature Importance en Random Forest).
   - Calcular la **Permutation Feature Importance** evaluada en el conjunto de test.
   - **Dilema Crítico:** Explicar por qué la importancia por MDI exhibe un sesgo sistemático a favor de variables numéricas continuas con alta cardinalidad frente a variables dummy discretas, y cómo la permutación en test neutraliza este sesgo.

🏛️ FASE 4: Inferencia Causal, Causal ML y el Choque Causal vs Predictivo

(Articulación directa con Unidad 6)

En esta fase (temática central de la **Unidad 6**), el equipo da el salto epistemológico decisivo: pasar de la asociación estadística a la prescripción de políticas mediante la teoría formal de causalidad estructural de Judea Pearl.



1. **Formalización del Grafo Acíclico Dirigido (DAG):**
   - Construir el DAG estructural en formato DOT o mediante `networkx` / `DoWhy`, explicitando los supuestos teóricos causales del dominio aprendidos en la Unidad 6.
   - Identificar y justificar formalmente en la narrativa:
     - La variable de **Tratamiento** ($T \in \{0, 1\}$ o continua).
     - La variable de **Resultado** (Y).
     - El conjunto de **Confusores Observables** (Z).
     - Las variables **Mediadoras** (M) y posibles **Colisionadores** (C).
2. **Identificación Causal y Criterio de Puerta Trasera (Backdoor Criterion):**
   - Demostrar analíticamente que el conjunto de ajuste Z bloquea todos los caminos espurios de puerta trasera entre T e Y sin abrir caminos colisionadores ni condicionar sobre mediadores.
   - Pregunta Trampa: ¿Qué ocurriría si el modelo de regresión causal incluye la variable mediadora M? (Bloquea el efecto indirecto del tratamiento, estimando únicamente el efecto directo y subestimando el impacto total de la política).
   - ¿Qué ocurriría si se condiciona sobre un colisionador C ($T \rightarrow C \leftarrow Y$)? (Introduce sesgo de Berkson o correlación inducida espuria).
3. **Flujo de Estimación en 4 Pasos con `DoWhy`:**
   - **Model:** Declaración de `CausalModel` vinculando datos y grafo causal.
   - **Identify:** Ejecución del motor de identificación causal (`identify_effect`) bajo el criterio Backdoor.

- **Estimate:** Estimar el **Efecto Causal Promedio (ATE)** mediante dos metodologías:
  1. Regresión lineal multivariada con ajuste de covariables Backdoor (`method_name="backdoor.linear_regression"`).
  2. Ponderación por Propensión Inversa (**IPW** / Propensity Score Weighting, `method_name="backdoor.propensity_score_weighting"`).
- **Comparación:** Contrastar el ATE causal estimado frente al coeficiente ingenuo de una regresión simple $Y \sim T$. Explicar cuantitativamente la dirección y magnitud del sesgo de confusión (confounding bias).

4. **Causal Machine Learning y Heterogeneidad de Efectos con `EconML` :**
   - Implementar **Double Machine Learning (DML)** mediante `LinearDML` o `CausalForestDML` .
   - Utilizar modelos de Machine Learning no lineales (ej. Random Forest) como modelos de ruido (nuisance models) para predecir T a partir de Z y para predecir Y a partir de Z, aislando la relación ortogonal residual entre T e Y.
   - Estimar el **Efecto Causal Promedio Condicional (CATE)** en función de covariables clave:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$$

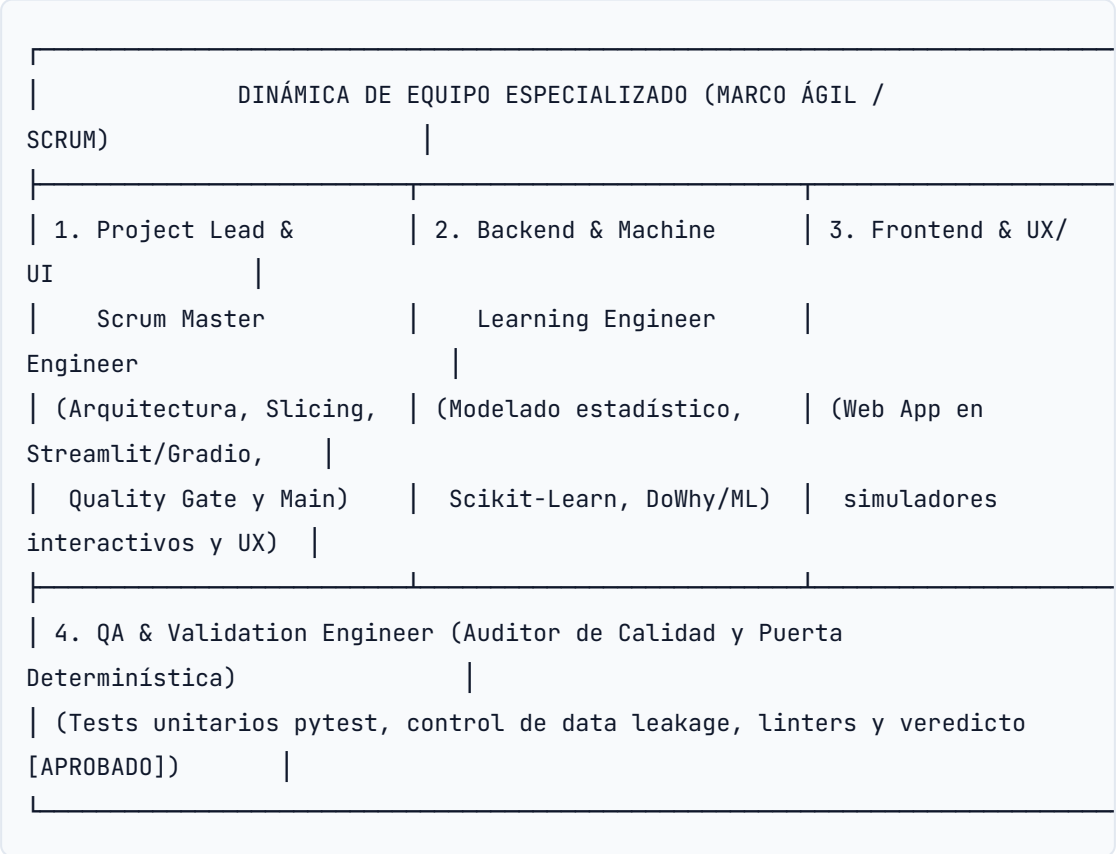
   - Graficar curvas de CATE: ¿En qué subgrupos de la población la intervención es altamente costo-efectiva y en cuáles genera un efecto neutro o contraproducente?

5. **Batería de Pruebas de Refutación Estocástica:**
   - Someter la estimación causal a tres pruebas de sensibilidad en `DoWhy` :
     - Random Common Cause: Añadir una variable de ruido independiente al DAG. Si el ATE varía significativamente, la identificación es frágil.
     - Placebo Treatment Refuter: Reemplazar T por una variable aleatoria permutada. El ATE estimado debe converger a cero ($p > 0.05$).
     - Data Subset Refuter: Re-estimar el ATE sobre submuestras aleatorias del 80%. El valor debe mantenerse dentro del intervalo de confianza original.

6. **El Ensayo Crítico: El Choque Causal vs Predictivo:**
   - Cada equipo redactará en el notebook una sección de discusión metodológica respondiendo:
     - Si la variable X_k resultó ser la de mayor importancia en el Random Forest de la Fase 3, ¿puede la dirección ejecutiva considerarla como una palanca para intervenir el sistema?
     - ¿En qué condiciones una variable altamente predictiva carece por completo de poder causal, o incluso tiene un efecto causal de signo opuesto al de su coeficiente correlacional?

💻 FASE 5: Dinámica de Equipo Ágil (Scrum), Bitácora y Deploy en Producción

El proyecto no es un script solitario; es un artefacto de ingeniería de software y ciencia de datos de producción desarrollado por un equipo estructurado.



A. Organización del Equipo bajo Roles Scrum

Cada integrante del grupo (3 a 4 estudiantes) asume la responsabilidad formal de uno de los siguientes roles especializados, los cuales deben quedar explícitamente documentados en el encabezado del repositorio y en la defensa oral:

1. 👑 **Project Lead & Scrum Master (Product Owner):**
   - Responsable de la descomposición del proyecto en **rebanadas verticales (tracer bullets)**, definición de historias de usuario y contratos de datos entre fases.
   - Administra los issues y milestones en GitHub.
   - **Regla de Oro:** NUNCA aprueba un merge hacia la rama principal (`main`) sin la firma formal del QA Engineer.
2. ⚙ **Backend & Machine Learning / Causal Engineer:**
   - Desarrolla los pipelines limpios en Python, el modelado en Scikit-Learn, Statsmodels, DoWhy y EconML.

- Serializa modelos, escaladores y estructuras DAG en formatos reproducibles (`joblib` , `pickle` , `json`).

3. 🧭 **Frontend & UI/UX Engineer:**
   - Diseña y programa la aplicación web interactiva de toma de decisiones utilizando **Streamlit**, **Gradio** o **FastAPI + HTML**.
   - Garantiza claridad visual, tipografías legibles, dashboards responsivos y visualización fluida de intervalos de confianza y grafos.

4. 🔍 **QA & Validation Engineer (Auditor de Calidad):**
   - Diseña y ejecuta pruebas automáticas con `pytest` (verificación de no fuga de datos, test de supuestos, integridad de dimensiones).
   - Audita la reproducibilidad del entorno (`requirements.txt` o `uv.lock`) y el formato PEP8 (`ruff` / `flake8`).
   - Emite el veredicto formal `[APROBADO]` o `[BLOQUEADO]` en cada Pull Request antes de integrar a producción.

B. La Bitácora de Ingeniería (`BITACORA.md`)

En la raíz del repositorio, el equipo mantendrá un archivo markdown vivo denominado `BITACORA.md` . No es un resumen del notebook ni un historial de commits git; es el **cuaderno de laboratorio y registro de decisiones de ingeniería**. Debe contener 5 entradas obligatorias:

- **Entrada 1 — Marco Estratégico e Hipótesis:** Preguntas fundacionales, mapa conceptual de negocio y selección fundamentada del dataset.
- **Entrada 2 — Matriz de Decisiones Estadísticas y Supuestos:** Registro de supuestos testeados, violaciones encontradas y justificación teórica de cada remediación (ej. por qué se optó por Welch ANOVA frente a Kruskal-Wallis, por qué cierta transformación de variables).
- **Entrada 3 — Autopsia de Experimentos Fallidos (Data Autopsy):** Registro de al menos dos experimentos que no funcionaron (modelos sobreajustados, features con multicolinealidad severa, o parametrizaciones inestables), explicando qué se aprendió y cómo se corrigió.
- **Entrada 4 — Formalización del Debate Causal:** Justificación de cada arco en el DAG causal, análisis de plausibilidad de variables no observadas latentes y discusión de amenazas a la validez interna.
- **Entrada 5 — Trazabilidad y Uso Ético de Asistentes de IA:** Si el equipo utilizó herramientas de IA (Claude, ChatGPT, Gemini, Copilot), documentar: prompts de diseño utilizados, alucinaciones o errores lógicos detectados en el proceso, y pruebas determinísticas creadas por el equipo para refutarlos.

C. Deploy Interactivo en Producción (Web App)

El proyecto finaliza con un producto de software funcionando y accesible públicamente en la nube (Streamlit Community Cloud, Render, Hugging Face Spaces o mediante un contenedor Docker reproducible con instrucciones claras en `README.md`).

La aplicación web debe contar con tres módulos interactivos: 1. **Módulo de Diagnóstico y Exploración:** Permite al usuario filtrar la muestra, inspeccionar variables y proyectar casos en el espacio bidimensional de las dos primeras Componentes Principales (PCA). 2. **Módulo Predictivo ("What-Is"):** Un simulador donde el usuario ingresa valores de entrada para un nuevo sujeto y el sistema devuelve la predicción del mejor modelo (Random Forest o Logística), acompañada de su intervalo de predicción/probabilidad calibrada y la explicación de importancia de variables para ese caso. 3. **Módulo de Simulación Causal de Políticas ("What-If"):** Permite a un directivo evaluar una política de intervención ($do(T = t)$). La app muestra: * El DAG causal interactivo. * La estimación del ATE global. * La curva de heterogeneidad de efectos (CATE) según el perfil seleccionado. * Un panel de semáforo con el resultado de las tres pruebas de refutación de DoWhy para advertir al tomador de decisiones sobre el nivel de confianza causal del modelo. 4. (Bonus Desafiante — Copiloto de Decisión): Incorporar un agente conversacional / asistente interactivo dotado de herramientas (Function Calling / Tool Use) que permita a un decisor formular preguntas en lenguaje natural ("¿Cuál sería el impacto estimado si aplicamos la intervención a clientes de más de 45 años?") y el asistente consulte el motor causal subyacente para responder con datos precisos, respetando guardrails contra la invención de cifras.

---

5. Entregables Obligatorios y Formato de Presentación

La entrega final se realizará el **Miércoles 18 de Noviembre de 2026** a las 23:59 hs a través del repositorio institucional y el aula virtual EVA, constando de:

1. **Repositorio GitHub Profesional:**
   - Estructura de carpetas limpia y modular (`/src`, `/data` o script de descarga, `/notebooks`, `/app`, `/tests`).
   - `README.md` de calidad editorial con badges, diagramas explicativos, instrucciones de reproducción paso a paso y enlace público al deploy.
   - Archivo de dependencias fijado (`requirements.txt` o `pyproject.toml` gestionado con `uv`).

2. **Notebook Principal Reproducible (`TP_Integrador_Final.ipynb`):**
    - Estructurado rigurosamente según las 4 fases técnicas con narrativa profesional, explicaciones teóricas previas a cada bloque de código y gráficos titulados con ejes claros.
    - Ejecutado de punta a punta sin errores de ejecución ni celdas vacías (`Restart & Run All`).
3. **Bitácora de Ingeniería (`BITACORA.md`):**
    - Completa con las 5 entradas obligatorias firmadas por los responsables de rol Scrum.
4. **Enlace Público de la Web App Desplegada:**
    - URL funcional y operativa en la nube o contenedor Docker testeado.
5. **Defensa Oral y Presentación Ejecutiva (Semana 13):**
    - Exposición grupal de **12 a 15 minutos** con diapositivas en formato PDF (10 a 12 slides ejecutivas).
    - Estructura recomendada:
        - Slides 1-2: El problema de negocio y preguntas de valor.
        - Slides 3-4: Hallazgos inferenciales, ANOVA y supuestos de Gauss-Markov/PCA.
        - Slides 5-6: El torneo de Machine Learning y curvas de calibración.
        - Slides 7-8: El DAG causal, estimación de ATE/CATE y refutaciones en DoWhy.
        - Slide 9: Demostración en vivo de la Web App desplegada.
        - Slide 10: Conclusiones ejecutivas y reflexiones de la Bitácora.
    - Ronda de preguntas individuales del tribunal docente donde cada estudiante defenderá su contribución técnica según el rol asignado.

---

6. Resumen de Calificación por Dimensiones (100 puntos totales → 3.0 pts en Cursada)

Dimensión de Evaluación	Ponderación	Núcleo de Contenidos Evaluados
1. Inferencia Estadística y ANOVA	**15 pts**	Formulación de contrastes, EDA profundo, diagnóstico riguroso de normalidad/ homocedasticidad en muestras grandes, ANOVA/Welch y post-hoc.
2. Preparación de Datos, Gauss-Markov y PCA	**15 pts**	Diagnóstico de residuos MCO, outliers influyentes (Cook's D), VIF y PCA con estandarización estricta sin data leakage.
3. Torneo Predictivo y Machine Learning	**20 pts**	Modelos lineales/ regularizados, Naive Bayes, Árbol CART podado por ccp_α, Random Forest con K-Fold CV, curvas de calibración y MDI vs Permutación.
4. Inferencia Causal y Causal ML	**25 pts**	Formulación de DAG (Unidad 6), criterio Backdoor, DoWhy (ATE con IPW y regresión), Double ML y CATE en EconML, refutaciones estocásticas y ensayo crítico.
5. Metodología Ágil (Scrum) y Bitácora	**10 pts**	Dinámica de equipo Scrum, Quality Gate de QA, y cumplimiento de las 5 entradas de la `BITACORA.md` con autopsia de experimentos.
6. Deploy en Producción, Código y Defensa	**15 pts**	Web App interactiva desplegada en la nube, calidad modular del repositorio,

Dimensión de Evaluación	Ponderación	Núcleo de Contenidos Evaluados
		reproducibilidad y dominio técnico individual en la defensa oral.

$$\text{Puntos Obtenidos en la Cursada (máx. 3.0)} = \frac{\text{Puntaje Rúbrica (máx. 100)}}{100} \times 3.0$$

(Para consultar el desglose pormenorizado de criterios por nivel de desempeño, referirse a la Rúbrica Detallada de Calificación).