¿El top-5 vende, o solo muestra lo que se vendería igual?

Retorno causal de un algoritmo de recomendación de hoteles

Verónica Ana López Marsico Lucía Báez Antonella Robiollio

Pontificia Universidad Católica Argentina, Facultad de Ingeniería y Ciencias Agrarias, Licenciatura en Ciencia de Datos
Estadística Aplicada y Modelos de Regresión (EAyMR 2026) · Profesor: Ivan Gonzalo Vilaboa

18 de noviembre de 2026

Resumen. Estimamos el efecto causal de que un recomendador exponga un hotel en los cinco primeros lugares de una búsqueda sobre su probabilidad de reserva, con los datos de Expedia del desafío ICDM 2013. Una fracción de las búsquedas se mostró en orden aleatorio, lo que nos permite contrastar empíricamente el supuesto de identificación por ajuste (criterio Backdoor) contra un benchmark cuasi-experimental. Combinamos inferencia clásica, diagnóstico de Gauss-Markov y PCA, un torneo predictivo calibrado y estimación causal con DoWhy, logit condicional por búsqueda y Double Machine Learning. Con orden aleatorio, el top-5 multiplica por 2,11 las chances de ser el hotel reservado de la lista (OR intra-búsqueda, IC 95 % [1,90; 2,35]). Con el orden del algoritmo, la comparación ingenua da 5,38 y el ajuste por todos los confusores observados, 3,38: el ajuste explica el 50 % del sesgo y el resto es compatible con confusión no observada (cociente de OR 1,60, IC bootstrap [1,42; 1,80]). El efecto es heterogéneo: 11,0 reservas incrementales cada 1.000 exposiciones para hoteles baratos y bien ubicados frente a 4,2 para hoteles caros y mal ubicados. La variable más predictiva del mejor modelo no es una palanca de la misma magnitud: valuar el slot con datos del algoritmo lo sobreestima.

Palabras clave: inferencia causal; criterio Backdoor; Double Machine Learning; sistemas de recomendación; sesgo de posición; experimento natural.

1. Introducción

Un buscador de hoteles muestra unos 25 resultados por búsqueda, pero la atención del usuario se concentra en los primeros. Los slots superiores son un recurso escaso y de suma cero, y el recomendador elige quién los ocupa: suele elegir hoteles que se reservarían igual. La pregunta operativa es si el slot **causa** reservas o solo las **predice**, porque de eso depende cuánto vale un posicionamiento pago y a quién conviene asignarlo. Formalmente, buscamos $P(Y \mid do(T = 1)) - P(Y \mid do(T = 0))$ y no $P(Y \mid T = 1) - P(Y \mid T = 0)$ [1].

La dificultad es la confusión: el ranker usa atributos del hotel que también causan la reserva, y algunos no los observamos. El dataset ofrece una salida poco común: una fracción de las búsquedas se mostró en orden aleatorio [2]. Contribuimos tres cosas: (i) contrastamos empíricamente el supuesto Backdoor, comparando el efecto estimado con el orden del algoritmo contra el benchmark aleatorio; (ii) cuantificamos qué parte del sesgo corrige el ajuste por lo observable; (iii) traducimos la heterogeneidad del efecto (CATE) en una regla de asignación del slot con valor esperado en reservas y dólares. Agregamos dos preguntas propias: qué tan aleatorio es el orden aleatorio y cómo condiciona la selección del dataset lo que se puede estimar.

2. Datos y auditoría

Usamos `train.csv` de la competencia [3]: 9.917.530 filas búsqueda × hotel en 399.344 búsquedas. Trabajamos con 30.000 búsquedas completas (739.323 filas), muestreadas por búsqueda y estratificadas por `random_bool`, con semilla fija. La partición 80/20 es agrupada por búsqueda y estratificada por `random_bool`. Como depende solo del identificador y de la semilla, la fijamos antes de transformar: cercas, cuantiles de winsorización y medianas de imputación se ajustan solo con Train, y un test verifica que perturbar Test no cambia ninguna fila de Train. Los datos son confidenciales según las reglas de la competencia: no están en el repositorio y la aplicación usa solo agregados.

Tabla 1. Centinelas (0 = sin dato): distorsión antes y después de pasarlos a faltante con indicador.

Variable	% filas	Media	Desvío
Puntaje de reseñas	5,2	3,76 → 3,96	1,08 → 0,65
Estrellas	3,4	3,19 → 3,30	1,05 → 0,88
Log precio histórico	14,8	4,30 → 5,05	1,86 → 0,52

La auditoría encontró cinco anomalías con génesis distinta (NB 1.2-1.3):

- **Centinelas.** Tres variables codifican "sin dato" con 0; tratarlos como valores sesga medias y desvíos (Tabla 1).
- **Escala del precio.** El 3,2 % de las reservas de dos o más noches informa el precio por estadía y no por noche, con proporciones distintas entre sitios. Lo neutralizamos con el precio relativo a la mediana de la búsqueda.
- **Extremos.** 1.449 filas caen fuera de las cercas extremas de Tukey sobre el log del precio ([8,43; 1.947,77] USD) o a más de diez veces la mediana de su búsqueda.
- **Slots estructurales.** Las posiciones 5, 11, 17, 23 casi nunca están en los datos: las ocupan listados que Kaggle no publica.
- **Selección.** Ninguna búsqueda tiene cero clics, y con el orden del algoritmo casi todas terminan en reserva: el dataset está seleccionado sobre el mediador y, en ese estrato, sobre el resultado.

Faltantes. Para $R_j = 1\{X_j \text{ falta}\}$, MCAR implica $R_j \perp X_{\text{obs}}$. Lo contrastamos variable por variable (χ^2

[*] Código, notebook ejecutado y tests: https://github.com/verolopezmar/TPI_Estadistica-avanzada-. App interactiva: `<URL_APP>`. Toda cifra del texto se lee de `models/resultados.json`, generado por el notebook `notebooks/TP_Integrador_Final.ipynb`; sus secciones se citan como NB x.y.

o Mann-Whitney con Bonferroni, más tamaño de efecto) y en forma conjunta con el test de Little [4]: $d^2 = 75.952$ con 73 gl, $p < 10^{-300}$. **Se rechaza MCAR.** Las variables con dependencia apreciable de lo observado (por ejemplo `location_score2`, con $|\text{SMD}| = 0{,}51$) se tratan como MAR: mediana por grupo ajustada en Train más un indicador. Las ausencias estructurales (historial del usuario y afinidad, con 95,5 % y 94,3 % de faltantes) son MNAR por construcción y no se imputan: se representan con un indicador.

Exploración. El precio relativo de los hoteles reservados está corrido a la izquierda del de los no reservados, y crece con la categoría (Figura 1). Spearman y Pearson difieren a lo sumo en 0,030, así que las relaciones son aproximadamente monótonas y lineales en estas escalas. La variable más asociada a la posición es `location_score2` (ρ = -0,172: mejor ubicado, más arriba), y estrellas y precio histórico correlacionan 0,62, un bloque calidad-precio que auditamos con VIF en la Fase 2.

Competidores (Z_c). Una variable es confusor solo si el ranking la usa ($Z_c \to T$) y además afecta la reserva ($Z_c \to Y$). Contrastamos las dos flechas por separado: la primera, con la interacción $Z_c \times R$ en un logit de T condicional a la calidad (si el orden aleatorio rompe la asociación, el algoritmo la usaba); la segunda, con el efecto sobre la reserva en el estrato aleatorio (Tabla 2).

3. Métodos

3.1. Marco formal

Con resultados potenciales $Y_{is}(t)$, los estimandos son el efecto promedio $\tau = \mathbb{E}[Y(1) - Y(0)]$, el condicional $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$ y su promedio por segmento $\tau_S = \mathbb{E}[\tau(X) \mid X \in S]$ (Tabla 3). Como la selección del dataset infla la escala absoluta de forma distinta en cada estrato, el estimando principal es relativo y dentro de la búsqueda: el odds ratio condicional $\psi = e^{\gamma}$ del logit condicional de McFadden [5],

$$P\Big(Y_{is} = 1 \Big| \textstyle\sum_{j \in s} Y_{js} = 1\Big) = \frac{\exp(\gamma T_{is} + Z_{is}^{\top}\delta)}{\sum_{j \in s} \exp(\gamma T_{js} + Z_{js}^{\top}\delta)}, \quad (1)$$

que condiciona en el número de reservas de la lista: el término de cada búsqueda (intención, destino, fecha) se cancela, y ψ no depende de cuántas listas con compra seleccionó el proveedor, por la misma lógica que en los estudios caso-control [6]. La identificación descansa en tres supuestos: SUTVA, que es una aproximación porque los slots son de suma cero; positividad, $0 < e(z) = P(T = 1 \mid Z = z) < 1$; e intercambiabilidad condicional, $Y(t) \perp T \mid Z$.

Identificación. En el DAG (Figura 2), todo camino trasero entre T e Y entra a T por Z o por U. Ajustar por Z bloquea los primeros sin abrir caminos nuevos, porque Z no contiene colisionadores ni descendientes de T; el clic y la selección quedan fuera del ajuste. $T \leftarrow U \to Y$, en cambio, queda abierto: con el orden del algoritmo, Backdoor no se cumple si U existe. Con $R = 1$, la intervención elimina los arcos que entran a T salvo $R \to T$ y el conjunto vacío alcanza. Doce pruebas de d-separación lo verifican (`tests/test_dag.py`). La comparación entre estratos es, entonces, un contraste empírico del supuesto Backdoor.

3.2. Estimadores

- **DoWhy en cuatro pasos** [7]: modelo con el DAG, identificación Backdoor (que excluye el mediador), estimación por regresión lineal con ajuste y por IPW, y refutación. El IPW es el estimador normalizado de Hájek, con la propensión $\hat{e}(z)$ de una logística escalada sobre Z:

$$\hat{\tau}_{\text{IPW}} = \frac{\sum_i T_i Y_i / \hat{e}_i}{\sum_i T_i / \hat{e}_i} - \frac{\sum_i (1 - T_i) Y_i / (1 - \hat{e}_i)}{\sum_i (1 - T_i) / (1 - \hat{e}_i)}.$$

  Como resguardo, excluimos las unidades con $\hat{e} \notin [0{,}01; 0{,}99]$ [8].
- **Logit condicional** (ecuación 1), estimado por Newton-Raphson con errores robustos por búsqueda, y un modelo lineal de probabilidad con efectos fijos de búsqueda para la escala absoluta.
- **Double Machine Learning** [9]: predecimos Y y T desde (W, X) con Random Forest y *cross-fitting* por búsqueda, y regresamos $Y - \hat{m}$ sobre $\tau(X)(T - \hat{e})$. Por la ortogonalidad de Neyman, los errores de $\hat{m}$ y $\hat{e}$ entran solo en segundo orden. Usamos `LinearDML` y `CausalForestDML` [10, 11] con X = estrellas, precio relativo, ubicación y usuario recurrente.
- **Incertidumbre y robustez:** bootstrap percentil por búsqueda ($B = 1000$), las tres refutaciones de DoWhy y simulaciones con verdad conocida de la selección S y del colisionador C.

3.3. Inferencia, regresión y predicción

Fijamos $\alpha = 0{,}05$ a priori y reportamos, junto con cada p-valor, el tamaño de efecto y el efecto mínimo detectable con potencia 0,80, $\text{MDE} = (z_{1-\alpha/2} + z_{1-\beta})\sqrt{1/n_1 + 1/n_2}$ en desvíos. Los contrastes se hacen sobre unidades independientes (búsquedas o reservas), no sobre filas. Con n en miles, Shapiro-Wilk rechaza ante desvíos irrelevantes; como t y F dependen de medias cuya asimetría decae como $\gamma_1/\sqrt{n}$, evaluamos la normalidad con asimetría, curtosis y Q-Q. Ante varianzas desiguales usamos Welch [12] y Games-Howell [13], con Kruskal-Wallis, Tukey y Bonferroni de resguardo. El modelo lineal de referencia es $\log(\text{precio}) = \beta_0 + \sum_k \beta_k X_k + \varepsilon$, estimado por MCO; contrastamos la homocedasticidad con Breusch-Pagan [14] y White, y usamos errores HC3 [15] y Huber [16] como resguardo. El PCA se ajusta solo con Train. El torneo compara una logística regularizada, Naive Bayes, CART podado y Random Forest [17] con `StratifiedGroupKFold(5)` por búsqueda, PR-AUC como métrica de selección (la prevalencia de reservas ronda el 2 %) y el umbral de decisión elegido en Train. Implementamos los modelos con statsmodels [18] y scikit-learn [19].

4. Resultados

4.1. Inferencia clásica y supuestos

Con orden aleatorio, la tasa de clic del top-5 es 2,16 veces la del resto de su lista (Tabla 4; diferencia 0,0561, IC 95 % [0,0531; 0,0590]; Wilcoxon de resguardo, $p =$

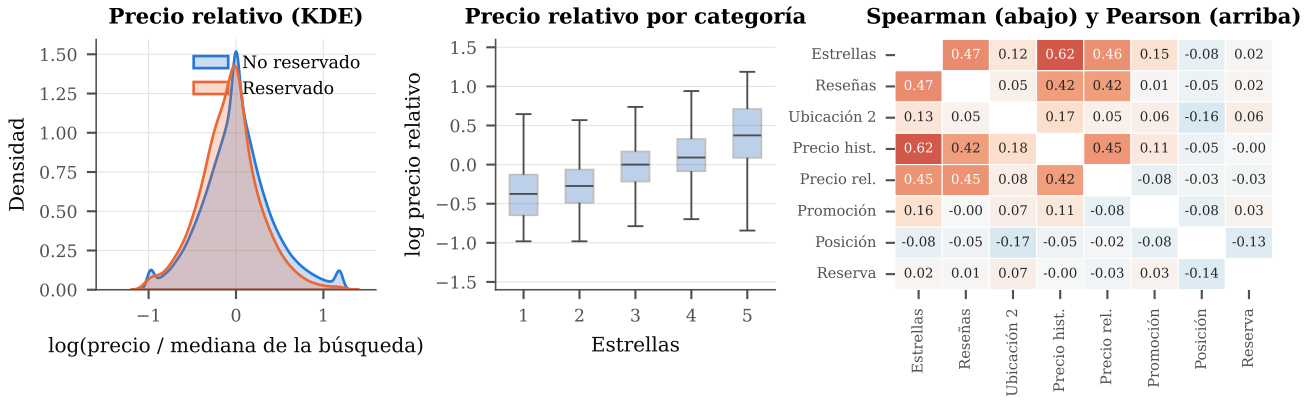


Figura 1. Exploración: densidad del precio relativo según reserva, precio relativo por categoría y correlaciones de Spearman (triángulo inferior) y Pearson (superior).

Tabla 2. Clasificación de las variables de competidores: razón de OR de la interacción con R en el logit de T y OR sobre la reserva con orden aleatorio.

Variable	$Z_c \to T$: razón de OR	$Z_c \to Y$: OR	Clase
`comp_n_info`	1,019 ($p = 2{,}87 \cdot 10^{-5}$)	1,118 ($p = 2{,}90 \cdot 10^{-17}$)	Confusor (débil en T)
`comp_saldo`	0,842 ($p = 2{,}67 \cdot 10^{-18}$)	1,137 ($p = 0{,}041$)	Confusor
`comp_diff_max`	0,999 ($p = 0{,}054$)	0,998 ($p = 0{,}534$)	Se excluye

Tabla 3. Variables y roles en el DAG. La unidad es el par búsqueda $s \times$ hotel i; la unidad independiente para la inferencia es la búsqueda.

Símbolo	Variable	Rol
Y_{is}	`booking_bool`	Resultado: el hotel i es el reservado en s
T_{is}	$1\{\texttt{position} \leq 5\}$	Tratamiento: exposición en el top-5
M_{is}	`click_bool`	Mediador; colisionador con I
Z	calidad, precio, competidores, contexto, usuario	Confusores observados
U, I	desempeño histórico; intención	Latentes
R_s	`random_bool`	Asignación: 1 = orden aleatorio
S_s	inclusión en el dataset	Selección (desc. de M y de Y)
C	"destacado" simulado	Colisionador $T \to C \leftarrow Y$

$7{,}70 \cdot 10^{-131}$). El efecto observado supera con holgura el MDE ($d_z = 0{,}023$): es el arco $T \to M$ del DAG (Figura 3). En el segundo contraste **no se rechaza** H_0. Eso no prueba que los gastos sean iguales: la muestra no detecta efectos menores que $g = 0{,}090$, y el cociente de medias geométricas es 1,039 [0,981; 1,101].

En el ANOVA del log del precio por noche según categoría (cuatro grupos, al menos 1.252 reservas por grupo), Shapiro rechaza en todos los grupos, pero las asimetrías van de -0,21 a 0,31, dentro de $[-1, 1]$, y la curtosis en exceso de 0,49 a 1,61: colas algo pesadas y simétricas, que el TCL absorbe con estos tamaños (Figura 4). Levene rechaza la homocedasticidad, así que la inferencia principal es el ANOVA de Welch, que rechaza $H_0 : \mu_{1\text{-}2} = \mu_3 = \mu_4 = \mu_5$. Kruskal-Wallis y los post-hoc de Games-Howell, Tukey y Bonferroni coinciden en todos los pares. Un hotel de cinco estrellas cuesta 2,65 veces uno de una o dos (medias geométricas).

4.2. Gauss-Markov y PCA

El MCO de referencia sobre 12.858 reservas de Train alcanza $R^2 = 0{,}604$ ($\bar{R}^2 = 0{,}603$; $F(17;\ 12.840) = 1.151$). La especificación ingenua sobre el precio crudo falla: $R^2 = 0{,}0028$, y una sola observación con distancia de Cook 1,21 domina el ajuste. Se rechazan la homocedasticidad y la normalidad de los residuos (Tabla 4; Figura 5). Como los coeficientes siguen insesgados, corregimos la varianza con HC3 y usamos Huber como resguardo ante colas pesadas. Hay 121 residuos estudentizados con $|r_i| > 3$, 841 puntos con $h_{ii} > 2(p{+}1)/n$ y 748 con $D_i > 4/n$ [20], pero ninguno con $D_i > 0{,}5$ (máximo 0,0117). Los influyentes se concentran donde el precio está en la escala equivocada; Huber coincide con MCO sin influyentes, así que no los eliminamos. El VIF máximo es 2,98: no hay multicolinealidad que resolver.

El PCA, ajustado solo con Train, retiene 4 componentes por Kaiser (69,7 % de la varianza); el codo sugiere dos (Figura 6). PC1 (32,6 %) ordena los hoteles de económicos a premium: cargan sobre todo `log_precio` (0,47), `prop_log_historical_price` (0,47), `prop_starrating` (0,44). PC2 representa la conveniencia: `prop_location_score1` (0,55) y `prop_location_score2` (0,48). Al proyectar Test a ciegas, los hoteles reservados se separan por PC2 y no por PC1 (NB 2.5): el usuario premia la oferta conveniente más que la categoría.

4.3. Torneo predictivo

El Random Forest gana en PR-AUC y Brier (Tabla 5, Figura 8). La búsqueda aleatoria sobre los cinco hiperparámetros pedidos elige `n_estimators` = 200, `max_depth` = 24, `min_samples_leaf` = 50, `min_samples_split` = 10 y `max_features` = log2. El error OOB (PR-AUC 0,151) converge con la CV, y un holdout cronológico da 0,144. Sin restricciones, el árbol crece hasta 18.863 hojas y memoriza Train (PR-AUC

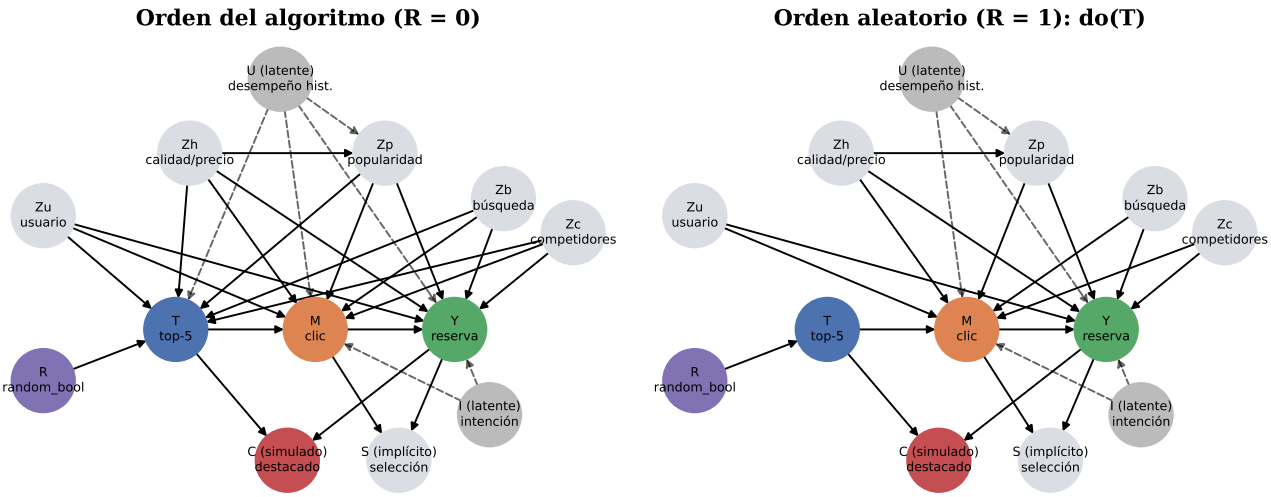


Figura 2. DAG estructural. Izquierda: orden del algoritmo ($R = 0$); Z bloquea los caminos traseros por Z pero no $T \leftarrow U \rightarrow Y$. Derecha: orden aleatorio ($R = 1$), cirugía de grafo de $do(T)$. Nodos grises: latentes; S y C: colisionadores.

Tabla 4. Contrastes de la Fase 1 (arriba) y diagnóstico de Gauss-Markov del MCO (abajo); $\alpha = 0{,}05$ fijado a priori. Estadístico con sus grados de libertad, p-valor exacto y tamaño de efecto.

Contraste	Estadístico	p	Efecto
Clic top-5 − resto (pareado)	$t(14.982) = 37{,}47$	$p = 7{,}74 \cdot 10^{-294}$	$d_z = 0{,}306$
Gasto: recurrentes − nuevos	$t(1.158{,}6) = 1{,}30$	$p = 0{,}193$	$g = 0{,}043$
Levene (Brown-Forsythe)	$F(3; 16.060) = 56{,}6$	$p = 2{,}27 \cdot 10^{-36}$	razón var. 1,59
ANOVA de Welch	$F(3; 4.432) = 1.807$	$p < 10^{-300}$	$\eta^2 = 0{,}254$
Kruskal-Wallis	$H(3) = 4.150$	$p < 10^{-300}$	$\varepsilon^2 = 0{,}258$
Breusch-Pagan	$LM = 515{,}9$ (17 gl)	$p = 8{,}34 \cdot 10^{-99}$	se rechaza
White	$LM = 985{,}4$	$p = 1{,}09 \cdot 10^{-117}$	se rechaza
Jarque-Bera	$JB = 4.236$	$p < 10^{-300}$	curtosis 5,81
Durbin-Watson	$d = 1{,}952$	—	sin autocorr.

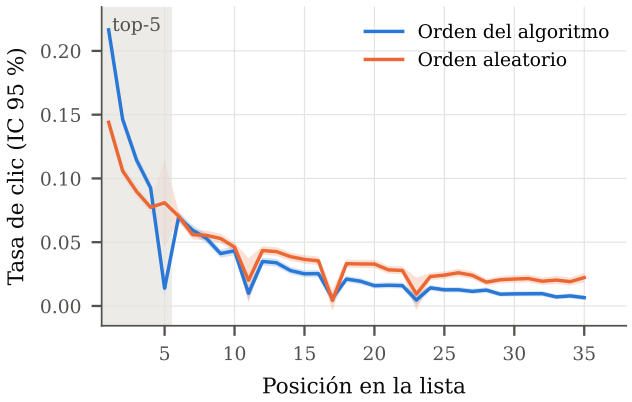


Figura 3. Tasa de clic por posición con el orden del algoritmo y con orden aleatorio (IC 95 %). Con orden aleatorio, la caída es efecto de la posición; la brecha entre curvas es selección del algoritmo.

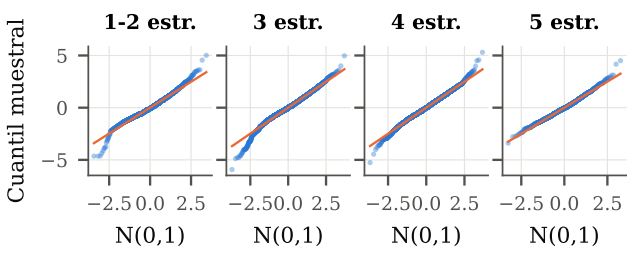


Figura 4. Q-Q del log del precio por noche (estandarizado) en cada categoría del ANOVA.

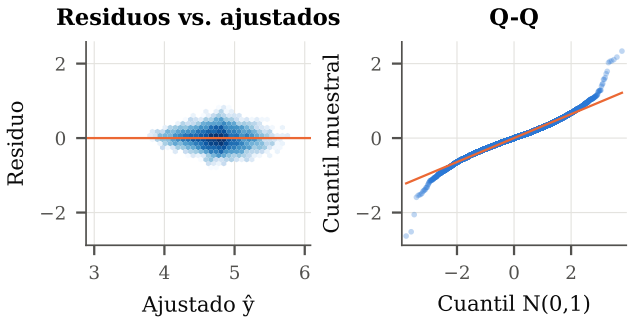


Figura 5. Diagnóstico del MCO: residuos vs. ajustados (celdas con al menos 10 observaciones) y Q-Q de los residuos.

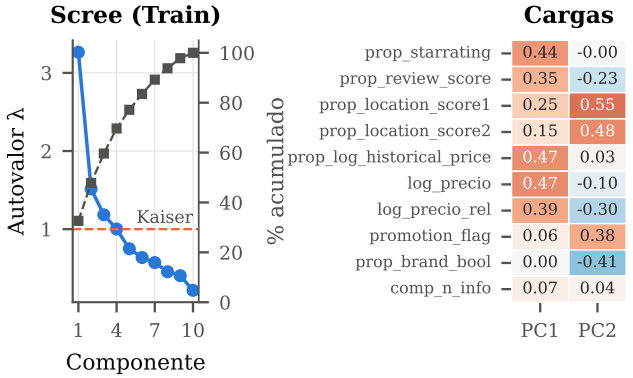


Figura 6. PCA ajustado en Train: autovalores con el criterio de Kaiser y varianza acumulada (izquierda); cargas de PC1 y PC2 (derecha).

Tabla 5. Desempeño en Test: AUC de las curvas ROC y precisión-recall, Brier y F1 (umbral elegido en Train por máximo F1). Precisión, recall y F1 ponderado, en NB 3.5.

Modelo	ROC	PR	Brier	F1	F1 mac.
Logística	0,844	0,135	0,0198	0,216	0,596
Naive Bayes	0,796	0,074	0,0697	0,006	0,497
CART podado	0,823	0,120	0,0198	0,216	0,593
Random Forest	0,854	0,153	0,0196	0,230	0,601

Tabla 6. Odds ratios de la logística sin penalizar (Train, variables en sus unidades originales, errores robustos por búsqueda): las ocho variables con menor p-valor (sin el prefijo prop_). Son asociaciones, no efectos causales.

Variable	OR	IC 95 %	p
`position`	0,899	[0,896; 0,902]	$< 10^{-300}$
`random_bool`	0,146	[0,139; 0,154]	$< 10^{-300}$
`location_score2`	4,381	[4,016; 4,780]	$8{,}43 \cdot 10^{-243}$
`log_precio_rel`	0,399	[0,377; 0,423]	$7{,}59 \cdot 10^{-214}$
`location_score2_faltante`	0,649	[0,616; 0,684]	$3{,}36 \cdot 10^{-58}$
`review_score`	1,296	[1,252; 1,341]	$9{,}82 \cdot 10^{-50}$
`location_score1`	0,915	[0,904; 0,926]	$6{,}48 \cdot 10^{-47}$
`log_precio`	0,755	[0,726; 0,785]	$5{,}14 \cdot 10^{-45}$

1,00 contra 0,031 en Test). La poda por complejidad $R_\alpha(T) = R(T) + \alpha|T|$, con α por CV, lo deja en 14 hojas, con la regla raíz `position` $\leq$ 4,5: la posición es lo que más reduce la impureza, y el segundo corte en ambas ramas es `random_bool`, que separa estratos con tasas base muy distintas (Figura 7). Ninguno de los dos cortes es una palanca causal. En la logística, cada posición más abajo multiplica las chances de reserva por 0,899 (IC 95 % [0,896; 0,902]), y `location_score2` tiene un OR de 4,38 (Tabla 6); son asociaciones, no efectos. Naive Bayes ordena aceptablemente pero sus probabilidades no sirven: la independencia condicional se viola y el modelo empuja las probabilidades a los extremos [21]. El MDI correlaciona con la cardinalidad de las variables ($\rho = 0{,}70$), porque una variable continua ofrece muchos más cortes que una dummy y gana splits por azar en Train [22]. La permutación en Test no premia esos cortes: la variable más importante es position.

Diseñamos dos sensibilidades no pedidas (NB 3.7). Primero, reemplazar las variables de hotel por las cuatro componentes principales de Train baja la PR-AUC de la logística de 0,135 a 0,119: la compresión pierde información predictiva, así que mantenemos las variables originales. Segundo, en las búsquedas de Test con reserva, el hotel reservado está en el top-5 del Random Forest en el 56,8 % de los casos con orden aleatorio, contra el 49,4 % del top-5 mostrado. Con orden aleatorio, ese top-5 no debería anticipar nada: su acierto es el efecto causal de la posición, que el modelo hereda y mejora con los atributos del hotel.

4.4. Efecto causal

Sesgo de confusión. Con el orden del algoritmo, el coeficiente ingenuo supera al ajustado (Tabla 7). El sesgo es positivo, porque el algoritmo pone arriba a hoteles que se reservarían igual, y equivale al 9,7 % del efecto de la regresión backdoor. La positividad [23] se cumple: con $R = 0$, solo el 0,010 % del resto y el 0,002 % del top-5 tienen $\hat{e} \notin [0{,}01; 0{,}99]$, y el IPW recortado coincide con el completo (Figura 9). El IC del IPW fija la propensión estimada, así que es conservador [24].

Observacional frente a benchmark. En la escala relativa intra-búsqueda (Figura 11), el top-5 multiplica las chances de reserva por 2,11 [1,90; 2,35] con orden aleatorio, por 3,38 [3,24; 3,52] con el orden del algoritmo ajustado por Z y por 5,38 sin ajuste. El ajuste explica el 49,8 % de la brecha en log-odds; el resto es compatible con U (conversión histórica del hotel, comisiones, inventario en tiempo real). La conclusión resiste tres objeciones (NB 4.3 bis):

1. **Población.** Re-ponderando las búsquedas del algoritmo a la composición de las aleatorias (la mayor |SMD| baja de 0,248 a 0,005), el cociente de OR es 1,59.
2. **No colapsabilidad del OR.** En diferencia de riesgos, el efecto marginal promedio es 5,34 p.p. con el algoritmo contra 3,24 p.p. con orden aleatorio (cociente 1,65, IC [1,41; 1,98]).
3. **Incertidumbre.** Wald de igualdad de log-OR: $z = 7{,}92$, $p = 2{,}34 \cdot 10^{-15}$. Bootstrap por búsqueda ($B = 1000$): cociente de OR 1,60 [1,42; 1,80], sin ninguna réplica ≤ 1 (Figura 10).

Trampas del mediador y del colisionador. Ajustar además por el clic reduce el efecto total de $\Delta p =$ 0,0778 a 0,0042: el modelo concluiría que la posición casi no importa, porque bloquea el canal por el que opera. Con orden aleatorio, el clic es el paso obligatorio del embudo: $\mathrm{RR}_{\mathrm{clic}} = 2{,}96$ y el 80 % del efecto en escala log pasa por más clics. En una simulación con verdad conocida, filtrar listas con al menos un evento (como hace el dataset) deja el OR condicional intacto (2,320 en ambos casos) y duplica la diferencia absoluta. Condicionar en un colisionador simulado C ($T \to C \leftarrow Y$) induce sesgo de Berkson: sobre los datos aleatorios, la Δp ingenua pasa de 0,0105 a 0,0136, y en la simulación el signo se invierte (NB 4.5). La Tabla 8 resume las tres demostraciones.

Refutaciones. La estimación por regresión backdoor pasa las tres refutaciones de DoWhy. Con una causa común aleatoria, el ATE no se mueve ($p = 0{,}485$). Con un placebo de T permutado, cae a -0,0002 ($p =$ 0,416). En submuestras del 80 % queda en 0,0962, dentro del IC original. Las tres miden estabilidad y no detectan U: eso lo hace el benchmark aleatorio. Para dimensionar cuánta confusión haría falta, simulamos un U que invierte una fracción de T y afecta a Y con la misma fuerza (Tabla 9): una confusión moderada alcanza para anular el efecto absoluto con el orden del algoritmo, lo que refuerza la necesidad del benchmark.

Heterogeneidad. El `LinearDML` con orden aleatorio muestra que el efecto baja con el precio relativo ($\theta =$ -0,0049, $p = 0{,}009$) y sube con la ubicación ($\theta =$ 0,0124, $p = 0{,}030$). El Causal Forest sobre los datos del algoritmo [25] muestra el mismo orden de segmentos con niveles inflados (Figura 13): la heterogeneidad no es un artefacto de U. Las curvas de CATE del bosque (Figura 12) muestran la forma: el efecto cae a partir de precios relativos cercanos a la mediana de la búsqueda y crece de manera monótona con la ubicación.

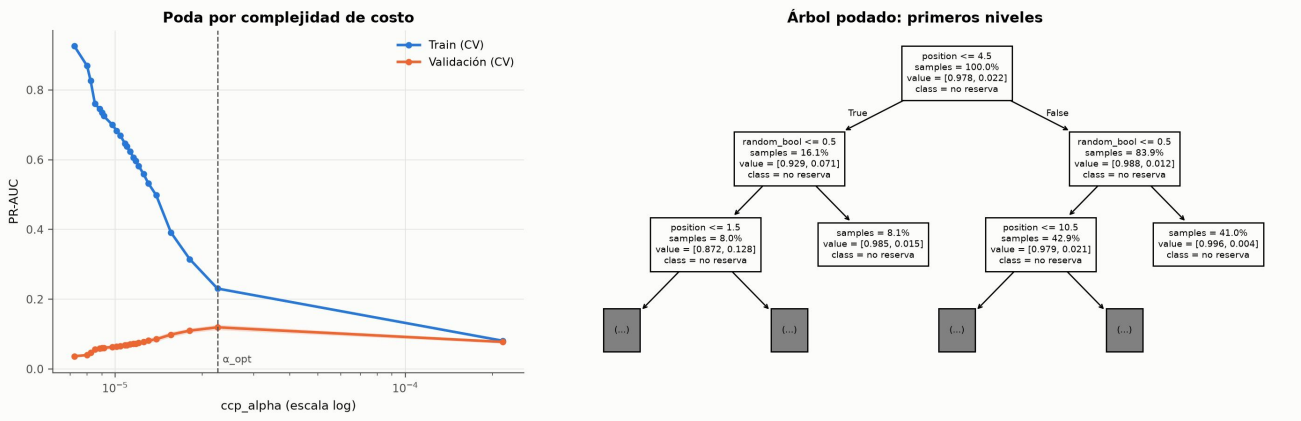


Figura 7. Árbol CART: PR-AUC en Train y validación según `ccp_alpha` (izquierda) y primeros niveles del árbol podado con el α elegido por CV (derecha). En cada nodo: regla de corte, proporción de filas y proporción de cada clase.

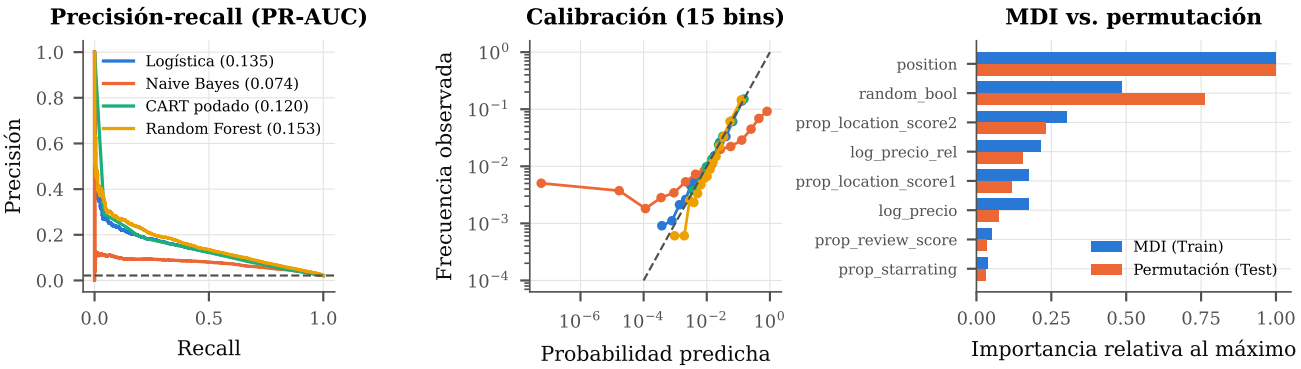


Figura 8. Torneo predictivo en Test: curvas precisión-recall (línea punteada: prevalencia), diagrama de confiabilidad e importancia por MDI (Train) y por permutación (Test), relativas al máximo de cada criterio.

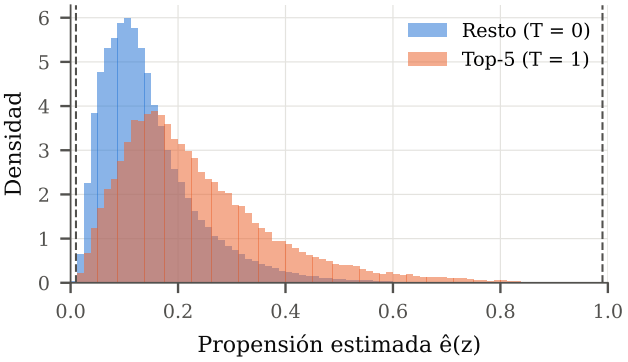


Figura 9. Overlap de la propensión estimada con el orden del algoritmo. Las líneas punteadas marcan el recorte en [0,01; 0,99].

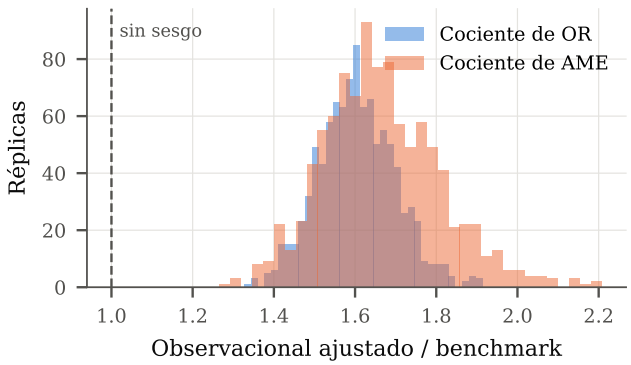


Figura 10. Distribución bootstrap por búsqueda ($B = 1000$) de los cocientes entre el efecto observacional ajustado y el benchmark, en OR y en efecto marginal promedio. La línea punteada marca la ausencia de sesgo.

En estrellas y en usuario recurrente es casi plano (NB 4.7).

5. Discusión

5.1. Capacidad predictiva frente a palanca causal

La posición es la variable más importante del Random Forest y la regla raíz del árbol. Leída como palanca, el OR ingenuo (5,38) diría cuánto gana un hotel al subirlo; el benchmark dice 2,11. La diferencia es selección: para predecir, la posición es útil justamente porque resume la calidad que el algoritmo ya vio, incluida la que no observamos. Una variable muy predictiva carece de poder causal, o lo tiene de signo opuesto, cuando es un proxy de confusores, cuando es conse-

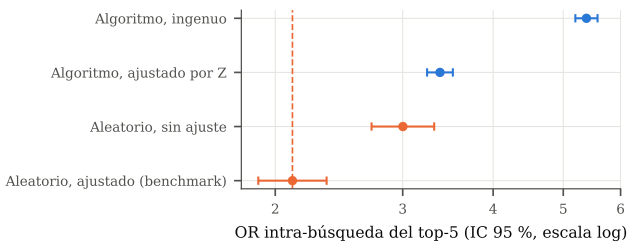


Figura 11. OR intra-búsqueda del top-5 (logit condicional, IC 95 %, escala log). La línea punteada es el benchmark aleatorio ajustado.

Tabla 7. Efecto del top-5 sobre P(reserva) en escala absoluta (IC 95 %). Los niveles no son comparables entre estratos: la selección del dataset infla la tasa base del algoritmo.

Estimador	Algoritmo ($R = 0$)	Aleatorio ($R = 1$)
Ingenuo $Y \sim T$	0,1055 [0,1032; 0,1078]	0,0105 [0,0096; 0,0115]
Regresión backdoor	0,0961 [0,0944; 0,0978]	0,0092 [0,0086; 0,0099]
IPW de Hájek	0,0882 [0,0854; 0,0909]	0,0078 [0,0069; 0,0088]
IPW recortado	0,0882 [0,0854; 0,0910]	0,0078 [0,0069; 0,0088]
LinearDML	0,0833 [0,0789; 0,0877]	0,0073 [0,0059; 0,0088]
Tasa base $P(Y \mid T = 0)$	0,0206	0,0037

Tabla 8. Trampas demostradas: ajustar por el mediador (arriba), seleccionar sobre el colisionador S en una simulación con verdad conocida, donde el OR condicional no cambia (medio), y condicionar en el colisionador simulado C (abajo).

Especificación	Δp	IC 95 %
Ajuste por Z (efecto total)	0,0778	[0,0753; 0,0803]
Ajuste por Z y por el clic M	0,0042	[0,0031; 0,0052]
Simulación: todas las listas	0,0338	[0,0302; 0,0373]
Simulación: solo listas con $S = 1$	0,0684	[0,0615; 0,0752]
Orden aleatorio: todas las filas	0,0105	[0,0096; 0,0115]
Orden aleatorio: condicionando en $C = 1$	0,0136	[0,0096; 0,0177]

Tabla 9. Sensibilidad a un confusor no observado simulado (regresión backdoor, orden del algoritmo; ATE original 0,0961).

Fuerza sobre T	Fuerza sobre Y	ATE con U	Cambio
1 %	1 %	0,0893	-7,1 %
2 %	2 %	0,0801	-16,7 %
5 %	5 %	0,0501	-47,8 %
10 %	10 %	-0,0147	-115,3 %

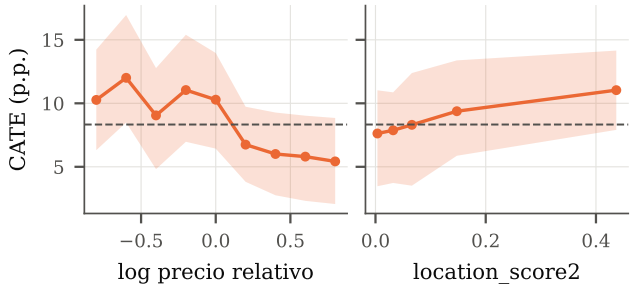


Figura 12. CATE del top-5 (Causal Forest DML, orden del algoritmo) en función del precio relativo y de la ubicación, con bandas de IC 95 %. La línea punteada es el ATE de LinearDML.

cuencia del resultado o un colisionador, o cuando la muestra está seleccionada sobre el resultado [26]. Los tres casos aparecen en estos datos: `random_bool` es la segunda variable más predictiva y no es una palanca, sino la huella del muestreo del proveedor; condicionar en C invierte el signo; ajustar por el clic anula el efecto. Solo el DAG, la identificación y, cuando existe, un experimento, permiten pasar de la asociación a la intervención.

5.2. Implicancias de negocio

1. **Valuar con el efecto causal.** Una valuación con datos del algoritmo, aun ajustada, sobrestima el OR del slot en un 60 %; un contrato de posicionamiento pago calculado así sobreprecia el inventario en esa proporción. Bajo supuestos explícitos sobre el efecto, el gasto y la fracción de reservas que se le quitan a otro hotel, 1.000 exposiciones en el top-5 valen entre 614 y 4.043 USD de gasto incremental (Tabla 11).
2. **Asignar por segmento.** El slot rinde 1,50 veces el promedio con hoteles baratos y bien ubicados, y 0,57 veces con hoteles caros y mal ubicados; los IC de esos dos segmentos no se superponen (Tabla 10). Reasignar 1.000 exposiciones del segundo grupo al primero suma 6,9 reservas, unos 1.530 USD.
3. **Experimentar en forma continua.** El orden aleatorio fue la única fuente que reveló el sesgo: mantener una fracción chica de tráfico aleatorio funciona como auditoría permanente del valor causal del ranking.

Tabla 10. Valor causal del slot por segmento con orden aleatorio (LinearDML): reservas y USD incrementales cada 1.000 exposiciones (gasto mediano de 223 USD, sin desplazamiento).

Segmento	Reservas	IC 95 %	USD
Barato y bien ubicado	11,0	[8,1; 13,9]	2.458
Barato para su búsqueda	9,0	[6,9; 11,1]	2.001
Bien ubicado	9,3	[6,9; 11,7]	2.067
Todos	7,3	[5,9; 8,8]	1.640
Mal ubicado	6,2	[4,5; 7,9]	1.376
Caro para su búsqueda	5,6	[3,9; 7,3]	1.244
Caro y mal ubicado	4,2	[2,2; 6,2]	929

Tabla 11. Valuación del slot por escenarios (cada 1.000 exposiciones). Conservador: límite inferior del IC del benchmark, gasto mediano y mitad de las reservas desplazadas de otro hotel; optimista: diferencia de tasas sin ajuste y gasto medio.

Escenario	Δp	Gasto	Desplaz.	Reservas	USD
Conservador	0,0055	223	50 %	2,8	614
Central	0,0064	223	0 %	6,4	1.438
Optimista	0,0105	383	0 %	10,5	4.043

5.3. Limitaciones y amenazas a la validez

- **Interna.** La aleatorización es imperfecta: con $R = 1$ persiste una asociación débil entre la posición y algunos atributos, que declaramos y ajustamos. La confusión por U en $R = 0$ queda cuantificada, no eliminada. SUTVA es aproximado: el estimando es el efecto dada la competencia de la lista.
- **Externa.** La población son búsquedas con al menos un clic de 2012-2013; el efecto sobre el tráfico total no está identificado.
- **De constructo.** T se define sobre la posición en pantalla; con el top-4 del dataset el OR es 2,13 [1,91; 2,37].

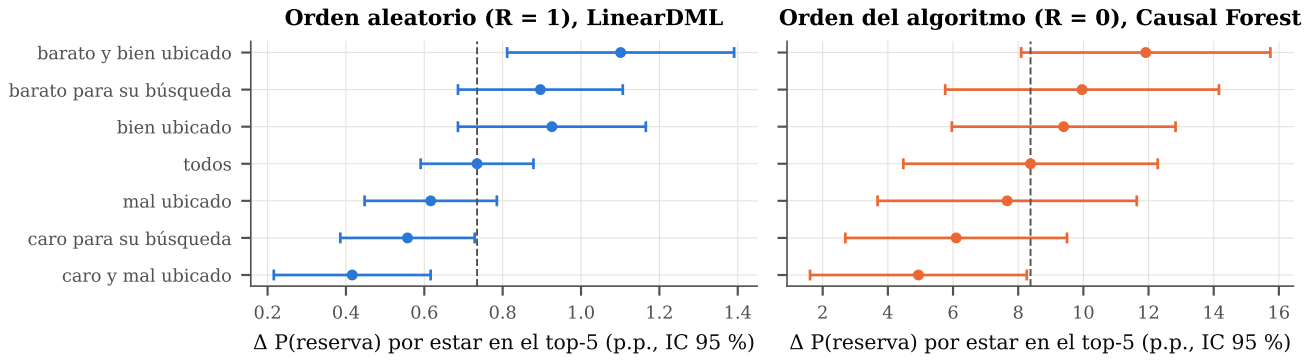


Figura 13. CATE del top-5 por segmento (terciles de precio relativo y de ubicación), IC 95 %. Izquierda: orden aleatorio, LinearDML; derecha: orden del algoritmo, Causal Forest DML. La línea punteada es el promedio de cada muestra.

- **Estadística.** Con n grande todo es significativo; por eso reportamos tamaños de efecto, MDE e IC por búsqueda. Los IC de los segmentos intermedios se superponen.
- **Licencia.** Los resultados publicados podrían considerarse parámetros del modelo según las reglas de Kaggle; es un riesgo asumido y documentado.

6. Conclusiones

El slot del top-5 tiene un efecto causal positivo sobre la reserva, que opera sobre todo a través de más clics. El dato observacional del algoritmo lo sobreestima aun después de ajustar por todo lo observable: el ajuste corrige la mitad del sesgo y la otra mitad es confusión no observada, de modo que el criterio Backdoor con las variables disponibles no alcanza en este sistema. El efecto es heterogéneo, y esa heterogeneidad se confirma con orden aleatorio. Recomendamos valuar y asignar el slot con el efecto causal por segmento y sostener una fracción de tráfico con orden aleatorio como auditoría. Más en general, un modelo predictivo excelente puede recomendar políticas equivocadas si su importancia de variables se lee como causal.

Declaración de uso de IA generativa

Usamos Claude Code [27] (Anthropic, modelo Claude Opus 5.5) como asistente de programación dentro del repositorio. El asistente propuso diseños, escribió código, tests y borradores de texto, y ejecutó el pipeline; el equipo definió los objetivos de cada fase, tomó y aprobó las decisiones y revisó cada incremento antes de integrarlo. Registramos 37 errores del asistente, cada uno con el test o la guarda que lo refuta: afirmaciones de memoria sin fuente primaria (la definición de `random_bool`, el signo de `compN_rate`), estimadores mal parametrizados (RANSAC por defecto, un logit condicional sin converger), resultados redactados antes de ver el output, y una fuga Train/Test en la preparación que detectamos en la auditoría de cierre y corregimos con un test que perturba Test y exige que Train no cambie. Ninguna cifra de este informe proviene del texto del asistente: todas se leen de `models/resultados.json`, generado por el notebook ejecutado. Los prompts, las decisiones y el detalle de cada error están en `docs/ia_log.md`.

Referencias

[1] J. Pearl. *Causality: Models, Reasoning, and Inference*. 2.ª ed. Cambridge: Cambridge University Press, 2009. DOI: 10.1017/CBO9780511803161.

[2] Expedia y Kaggle. *Personalize Expedia Hotel Searches – ICDM 2013*. Competencia de Kaggle. Datos y reglas de uso consultados el 12/11/2026. 2013.

[3] X. Liu, B. Xu, Y. Zhang et al. *Combination of Diverse Ranking Models for Personalized Expedia Hotel Searches*. 2013. arXiv: 1311.7679.

[4] R. J. A. Little. "A Test of Missing Completely at Random for Multivariate Data with Missing Values". En: *Journal of the American Statistical Association* 83.404 (1988), págs. 1198-1202. DOI: 10.1080/01621459.1988.10478722.

[5] D. McFadden. "Conditional Logit Analysis of Qualitative Choice Behavior". En: *Frontiers in Econometrics*. Ed. por P. Zarembka. New York: Academic Press, 1974, págs. 105-142.

[6] R. L. Prentice y R. Pyke. "Logistic Disease Incidence Models and Case-Control Studies". En: *Biometrika* 66.3 (1979), págs. 403-411. DOI: 10.1093/biomet/66.3.403.

[7] A. Sharma y E. Kiciman. *DoWhy: An End-to-End Library for Causal Inference*. 2020. arXiv: 2011.04216.

[8] R. K. Crump, V. J. Hotz, G. W. Imbens y O. A. Mitnik. "Dealing with Limited Overlap in Estimation of Average Treatment Effects". En: *Biometrika* 96.1 (2009), págs. 187-199. DOI: 10.1093/biomet/asn055.

[9] V. Chernozhukov, D. Chetverikov, M. Demirer et al. "Double/Debiased Machine Learning for Treatment and Structural Parameters". En: *The Econometrics Journal* 21.1 (2018), págs. C1-C68. DOI: 10.1111/ectj.12097.

[10] K. Battocchi, E. Dillon, M. Hei et al. *EconML: A Python Package for ML-Based Heterogeneous Treatment Effects Estimation*. Ver. 0.15.1. 2019.

[11] S. Wager y S. Athey. "Estimation and Inference of Heterogeneous Treatment Effects using Random Forests". En: *Journal of the American Statistical Association* 113.523 (2018), págs. 1228-1242. DOI: 10.1080/01621459.2017.1319839.

[12] B. L. Welch. "On the Comparison of Several Mean Values: An Alternative Approach". En: *Biometrika* 38.3/4 (1951), págs. 330-336. DOI: 10.1093/biomet/38.3-4.330.

[13] P. A. Games y J. F. Howell. "Pairwise Multiple Comparison Procedures with Unequal n's and/or Variances: A Monte Carlo Study". En: *Journal of Educational Statistics* 1.2 (1976), págs. 113-125. DOI: 10.3102/10769986001002113.

[14] T. S. Breusch y A. R. Pagan. "A Simple Test for Heteroscedasticity and Random Coefficient Variation". En: *Econometrica* 47.5 (1979), págs. 1287-1294. DOI: 10.2307/1911963.

[15] J. G. MacKinnon y H. White. "Some Heteroskedasticity-Consistent Covariance Matrix Estimators with Improved Finite Sample Properties". En: *Journal of Econometrics* 29.3 (1985), págs. 305-325. DOI: 10.1016/0304-4076(85)90158-7.

[16] P. J. Huber. “Robust Estimation of a Location Parameter”. En: *The Annals of Mathematical Statistics* 35.1 (1964), págs. 73-101. DOI: 10.1214/aoms/1177703732.

[17] L. Breiman. “Random Forests”. En: *Machine Learning* 45.1 (2001), págs. 5-32. DOI: 10.1023/A:1010933404324.

[18] S. Seabold y J. Perktold. “statsmodels: Econometric and Statistical Modeling with Python”. En: *Proceedings of the 9th Python in Science Conference*. 2010, págs. 92-96. DOI: 10.25080/Majora-92bf1922-011.

[19] F. Pedregosa, G. Varoquaux, A. Gramfort et al. “Scikit-learn: Machine Learning in Python”. En: *Journal of Machine Learning Research* 12 (2011), págs. 2825-2830.

[20] R. D. Cook. “Detection of Influential Observation in Linear Regression”. En: *Technometrics* 19.1 (1977), págs. 15-18. DOI: 10.1080/00401706.1977.10489493.

[21] A. Niculescu-Mizil y R. Caruana. “Predicting Good Probabilities with Supervised Learning”. En: *Proceedings of the 22nd International Conference on Machine Learning*. 2005, págs. 625-632. DOI: 10.1145/1102351.1102430.

[22] C. Strobl, A.-L. Boulesteix, A. Zeileis y T. Hothorn. “Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution”. En: *BMC Bioinformatics* 8 (2007), pág. 25. DOI: 10.1186/1471-2105-8-25.

[23] P. R. Rosenbaum y D. B. Rubin. “The Central Role of the Propensity Score in Observational Studies for Causal Effects”. En: *Biometrika* 70.1 (1983), págs. 41-55. DOI: 10.1093/biomet/70.1.41.

[24] K. Hirano, G. W. Imbens y G. Ridder. “Efficient Estimation of Average Treatment Effects Using the Estimated Propensity Score”. En: *Econometrica* 71.4 (2003), págs. 1161-1189. DOI: 10.1111/1468-0262.00442.

[25] S. Athey, J. Tibshirani y S. Wager. “Generalized Random Forests”. En: *The Annals of Statistics* 47.2 (2019), págs. 1148-1178. DOI: 10.1214/18-AOS1709.

[26] M. A. Hernán y J. M. Robins. *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC, 2020.

[27] Anthropic. *Claude Code*. Asistente de programación agéntico; modelo Claude Opus 5.5. 2026.