¿El top-5 vende, o solo muestra lo que se vendería igual?

Retorno causal de un algoritmo de recomendación — TPI Decision Intelligence Capstone, EAyMR 2026 (UCA)

Verónica López Marsico Lucía Báez Antonella Robiollio

2026-11-18

Estimamos el efecto causal de que el recomendador de Expedia exponga un hotel en los cinco primeros lugares de una búsqueda sobre su probabilidad de reserva, con los datos del desafío ICDM 2013. Un subconjunto de búsquedas mostró los hoteles en orden aleatorio: lo usamos como benchmark cuasi-experimental para contrastar empíricamente el supuesto Backdoor. El documento integra inferencia clásica, diagnóstico de Gauss-Markov y PCA, un torneo predictivo y la estimación causal con DoWhy, logit condicional por búsqueda y Double Machine Learning. Todo número del texto se lee de `models/resultados.json`, generado por el notebook anexo (`notebooks/TP_Integrador_Final.ipynb`).

Tabla de contenidos

1 Resumen ejecutivo **2**

2 Problema y preguntas **2**

3 Datos y auditoría forense **2**

4 Inferencia clásica **3**

5 Gauss-Markov y PCA **4**

6 Torneo predictivo **4**

7 Inferencia causal **6**
7.1 DAG e identificación . . . 6
7.2 DoWhy (regresión backdoor e IPW) . . . 6
7.3 Escala relativa: observacional vs. cuasi-experimento . . . 6
7.4 Robustez de la conclusión central . . . 7
7.5 El clic: paso obligatorio del embudo . . . 8
7.6 Trampas de selección y del colisionador . . . 8
7.7 Refutaciones . . . 8
7.8 Double Machine Learning y CATE . . . 9

8 Traducción a decisiones de negocio **9**

9 Limitaciones **9**

10 Reproducibilidad y gobernanza de la IA 10

Referencias 10

1. Resumen ejecutivo

- **El top-5 sí causa reservas, pero bastante menos de lo que sugieren los datos del algoritmo.** Con orden aleatorio, estar en el top-5 multiplica las chances de que un hotel sea el reservado de su lista por 2,11 (OR intra-búsqueda, ajustado). Con el orden del algoritmo, la comparación ingenua da 5,38; ajustando por los confusores observados, baja a 3,38.
- **La mitad del sesgo es explicable y la otra mitad no.** Ajustar por calidad, precio, competidores y contexto explica el 49,8 % de la brecha en log-odds. **Los datos son incompatibles con que el ajuste por lo observable elimine el sesgo:**
  - el OR observacional ajustado supera al benchmark por un factor de 1,60 (IC 95 % bootstrap por búsqueda [1,42; 1,80], 1000 réplicas);
  - en diferencia de riesgos, que es colapsable, el factor es 1,65 [1,41; 1,98];
  - el resultado se mantiene re-ponderando la muestra del algoritmo a la composición de la aleatoria.

  Candidatos de confusión no observada: la conversión histórica del hotel en Expedia, las comisiones y los acuerdos de visibilidad, el inventario en tiempo real y el comportamiento en la sesión.
- **Predecir no es intervenir.** El mejor modelo predictivo (Random Forest, PR-AUC 0,154 frente a una prevalencia del 2 %) usa la posición como su variable principal, pero buena parte de ese poder predictivo es selección del algoritmo y no efecto causal.
- **Decisión:** valuar el slot premium con el efecto causal, no con la tasa observada. Priorizar el top-5 donde el CATE es mayor (sección 6.6) y no extrapolar a búsquedas sin clic, que el dataset no contiene.

2. Problema y preguntas

Un buscador de hoteles muestra alrededor de 25 resultados por búsqueda, pero la atención del usuario se concentra en los primeros. Los slots superiores son un recurso escaso de suma cero, y el recomendador elige quién los ocupa: suele elegir hoteles que se venderían igual. La pregunta operativa es si el slot **causa** ventas o solo las **predice**, porque de eso depende cuánto vale un slot premium.

Preguntas:

1. ¿Cuál es el efecto causal de la exposición en el top-5 sobre la reserva (ATE/CATE)?
2. ¿Cuánto sesgo introduce estimarlo con el orden del algoritmo en lugar del orden aleatorio?
3. ¿El efecto pasa entero por el clic?
4. ¿Para qué hoteles y usuarios rinde más el slot?
5. *(Propias)* ¿Qué tan aleatorio es el orden aleatorio? ¿Cómo condiciona la selección del dataset lo que se puede estimar?

3. Datos y auditoría forense

Usamos `train.csv` de Kaggle (Liu et al. 2013): 9.917.530 filas búsqueda × hotel en 399.344 búsquedas. Trabajamos con una muestra de 30.000 búsquedas completas (739.323 filas), estratificada por

`random_bool`. Las reglas de la competencia declaran confidenciales los datos: ninguno está en el repositorio y la app usa solo agregados.

Hallazgos de la auditoría (detalle en el notebook, sección 1.2):

- **Centinelas.** El 0 de `prop_log_historical_price` (14,8 % de las filas) sesga su media un -14,8 %. Se pasa a faltante con indicador.
- **Desplazamiento de escala del precio.** El 3,2 % de las reservas de dos o más noches tiene el precio por estadía y no por noche, disperso entre sitios. Se neutraliza con el precio relativo a la mediana de la búsqueda.
- **Valores extremos.** 1.445 filas (0,195 %) quedan fuera de las cercas extremas de Tukey sobre el log del precio o a más de 10 veces la mediana de su búsqueda.
- **Slots estructurales.** Las posiciones 5, 11, 17, 23 casi nunca están en el dataset: las ocupan listados que Kaggle no publica.
- **Selección del dataset.** Ninguna búsqueda tiene cero clics, y el 94 % de las búsquedas con orden del algoritmo tiene una reserva, contra el 13 % con orden aleatorio. Esto condiciona en el mediador (y, en R = 0, en el resultado): es el colisionador natural de la sección 6.4.
- **Faltantes.** MCAR se rechaza en las cinco variables contrastadas. Las MAR se imputan por grupo con indicador; las MNAR estructurales (historial del usuario, afinidad) no se imputan.

4. Inferencia clásica

Contraste 1 (pareado, orden aleatorio). Dentro de cada búsqueda, la tasa de clic del top-5 supera a la del resto: t(14982) = 37.47, p = 7.74e-294, IC 95 % [0.05313; 0.05899], d_z = 0.306 (α = 0.05) → se rechaza H0. El cociente de tasas medias es 2,16, y el efecto mínimo detectable es d_z = 0,023. **El sesgo de posición existe:** es el arco $T \to M$ del DAG.

Contraste 2 (Welch, gasto por reserva, recurrentes vs. nuevos). t(1158.6) = 1.303, p = 0.193, IC 95 % [-0.0194; 0.09617], g de Hedges = 0.043 (α = 0.05) → no se rechaza H0. El cociente de medias geométricas es 1,039 (IC 95 % [0,981; 1,101]). Con el efecto mínimo detectable de g = 0,090, la muestra no puede distinguir diferencias más chicas.

ANOVA (log precio por noche según estrellas). Levene rechaza la homocedasticidad (F(3; 16060) = 56.57, p = 2.27e-36, razón de varianzas máx/mín = 1.590 (α = 0.05) → se rechaza H0), así que la inferencia principal es el ANOVA de Welch: F(3; 4432.0) = 1807, p < 1e-300 (subdesborde de doble precisión), η^2 = 0.254 (α = 0.05) → se rechaza H0. Kruskal-Wallis y los post-hoc de Games-Howell, Tukey y Bonferroni coinciden. Un hotel de 5 estrellas cuesta 2,65 veces uno de 1-2 estrellas (medias geométricas).

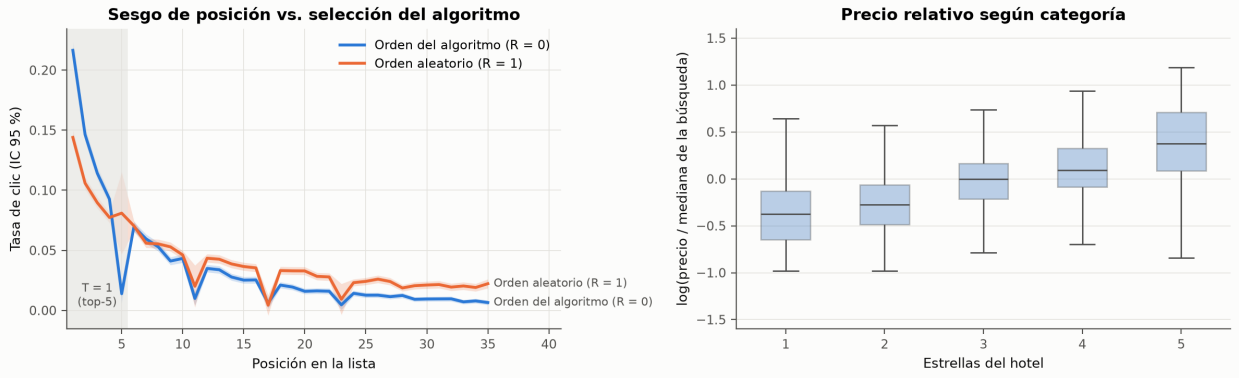


Figura 1: Sesgo de posición: tasa de clic por posición con orden del algoritmo y aleatorio (IC 95 %), y precio relativo por categoría.

5. Gauss-Markov y PCA

El MCO de referencia (log del precio por noche de 12.858 reservas de Train) da R^2 = 0,604. La especificación ingenua sobre el precio crudo fracasa: R^2 = 0,0028 y una distancia de Cook de 1,215 (Entrada 3 de la BITÁCORA).

Tabla 1: Auditoría de Gauss-Markov.

Supuesto	Resultado	Remediación
Homocedasticidad	Breusch-Pagan p = 4,96e-99	Errores HC3
Normalidad	Jarque-Bera p < 10^{-300}, curtosis 5,80	TCL + Huber
Independencia	Durbin-Watson 1,951	Ninguna
Influyentes	746 con $D > 4/n$, 0 con $D > 0,5$	Huber como resguardo
Multicolinealidad	VIF máx. 1,74 (modelo), 2,98 (Fase 3)	Ninguna

El PCA, ajustado **solo con Train**, retiene 4 componentes por Kaiser (69,7 % de la varianza). PC1 ordena los hoteles de económicos a premium; PC2 captura la buena ubicación a buen precio. En Test, los hoteles reservados se distinguen por PC2 y no por PC1.

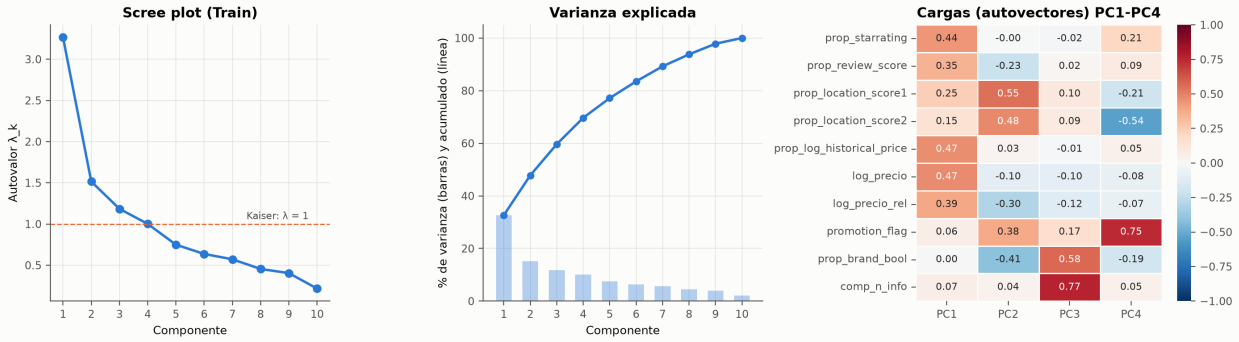


Figura 2: Scree plot, varianza explicada y cargas del PCA ajustado en Train.

6. Torneo predictivo

Partición 80/20 agrupada por búsqueda y estratificada por `random_bool`; CV `StratifiedGroupKFold` (5) dentro de Train; PR-AUC como métrica de selección (prevalencia ≈ 2 %).

Tabla 2: Desempeño en Test (umbral elegido en Train por máximo F1).

	ROC_AUC	PR_AUC	Brier	Precision	Recall	F1	F1_macro
Logística	0.8439	0.1350	0.0198	0.1678	0.3045	0.2164	0.5959
Naive Bayes	0.7960	0.0740	0.0697	0.0694	0.0031	0.0059	0.4973
CART podado	0.8232	0.1197	0.0198	0.1511	0.3788	0.2161	0.5926
Random Forest	0.8489	0.1540	0.0196	0.1873	0.3064	0.2325	0.6049

- **CART:** el árbol sin restricciones (18.896 hojas) memoriza Train (PR-AUC 1,000) y fracasa en Test (0,031). Podado con α_{opt}, queda en 14 hojas.

- **Random Forest:** el error OOB (PR-AUC 0,151) converge con la CV.
- **Holdout cronológico:** con el último 20 % del período da PR-AUC 0,146, cerca del holdout aleatorio.
- **Importancias:** el MDI correlaciona con la cardinalidad de las variables ($\rho = 0{,}75$). La importancia por permutación en Test corrige ese sesgo.

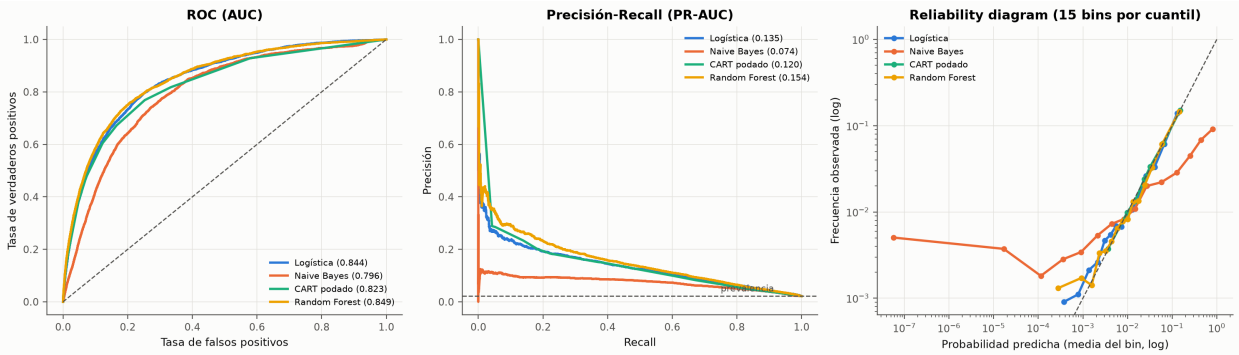


Figura 3: Curvas ROC, PR y diagramas de confiabilidad en Test.

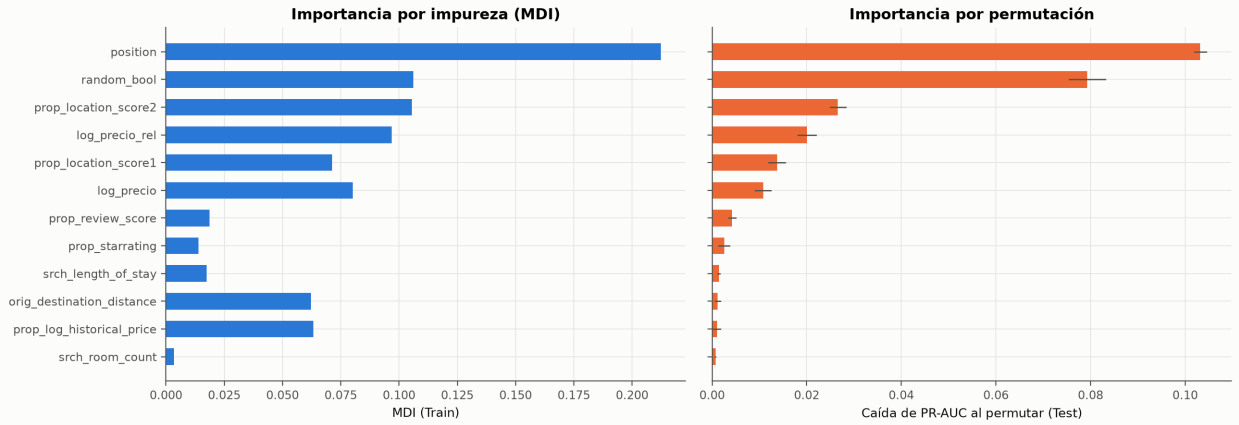


Figura 4: MDI (Train) vs. importancia por permutación (Test).

7. Inferencia causal

7.1. DAG e identificación

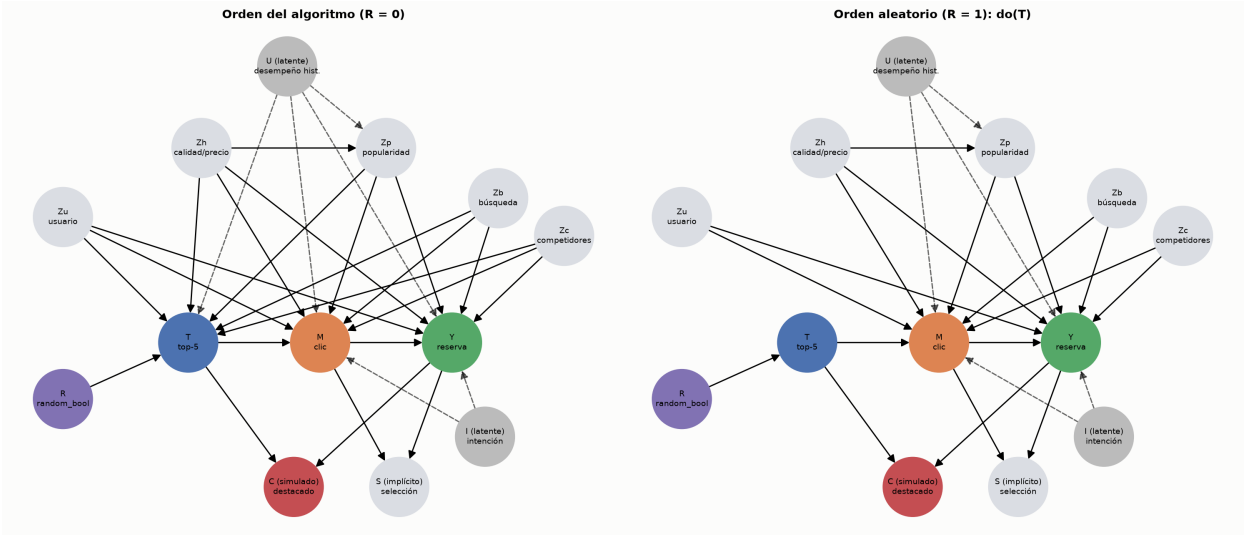


Figura 5: DAG con el orden del algoritmo y con orden aleatorio (cirugía de grafo de do(T)).

Con el orden del algoritmo, el conjunto Z (calidad y precio, popularidad, contexto, usuario y competidores) bloquea los caminos $T \leftarrow Z \rightarrow Y$, pero no $T \leftarrow U \rightarrow Y$. Backdoor no se cumple si U existe, y por eso es crucial el benchmark con orden aleatorio, donde el conjunto vacío alcanza. Lo verifican pruebas de d-separación (`tests/test_dag.py`).

7.2. DoWhy (regresión backdoor e IPW)

Tabla 3: Efecto del top-5 sobre P(reserva) en escala absoluta (DoWhy).

	ingenuo (Y ~ T)	regresión backdoor	IPW	tasa base P(Y|T=0)	sesgo relativo %
R = 0 (algoritmo)	0.1055	0.0961	0.0890	0.0206	9.7486
R = 1 (aleatorio)	0.0105	0.0092	0.0079	0.0037	14.5257

El ajuste reduce el coeficiente ingenuo. Las magnitudes absolutas **no** son comparables entre estratos, porque la selección del dataset infla la tasa base del orden del algoritmo.

7.3. Escala relativa: observacional vs. cuasi-experimento

Tabla 4: OR intra-búsqueda del top-5 (logit condicional) y diferencia de probabilidad con efectos fijos.

	OR intra	OR IC95	búsquedas informativas	MPL-EF (Δp)
R = 0 (algoritmo) | sin ajuste	5.382529	[5.196, 5.576]	14124	0.097316
R = 0 (algoritmo) | ajustado por Z	3.37772	[3.242, 3.519]	14124	0.077811
R = 1 (aleatorio) | sin ajuste	3.001915	[2.717, 3.316]	1971	0.00849
R = 1 (aleatorio) | ajustado por Z	2.112463	[1.895, 2.355]	1971	0.006441

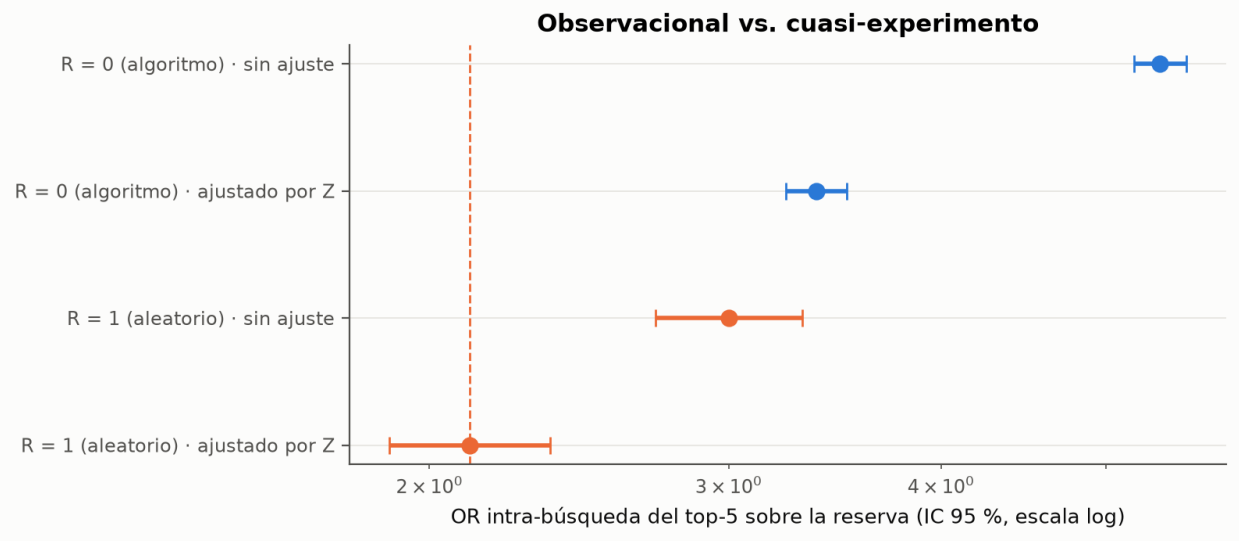


Figura 6: OR intra-búsqueda: observacional (orden del algoritmo) vs. benchmark (orden aleatorio).

La brecha entre el OR ingenuo del algoritmo y el benchmark es de 0,935 en log-odds. El ajuste por Z explica el 49,8 %. El resto es compatible con la confusión no observada U. La sensibilidad con T = top-4 del dataset da OR = 2,128.

7.4. Robustez de la conclusión central

La conclusión "el observacional ajustado sobreestima el efecto causal" se sometió a tres pruebas (notebook, 4.3 bis), todas sobre las búsquedas con una reserva, que son las que entran a los estimadores intra-búsqueda:

1. **Balance de poblaciones.** Antes de re-ponderar, la mayor |SMD| entre las búsquedas del algoritmo y las aleatorias es 0,248 (proporción de hoteles en promoción y largo de la lista). Con pesos de odds, la mayor |SMD| baja a 0,005, con un tamaño efectivo de 12.938 de 14.124 búsquedas. La brecha no se explica por una diferencia de población: re-ponderado, el cociente de OR es 1,594.
2. **No colapsabilidad del OR.** En escala de diferencia de riesgos (efecto marginal promedio del logit de elección), el top-5 suma 5,34 p.p. con el algoritmo contra 3,24 p.p. con orden aleatorio. La tasa base es comparable entre estratos en esta población (una reserva por lista).
3. **Incertidumbre.**
   - Test de Wald de la igualdad de log-OR: z = 7,92, p = 2,36e-15.
   - Bootstrap percentil clusterizado por búsqueda, con 1000 réplicas (Tabla 5).

Tabla 5: Bootstrap por búsqueda (IC 95 % percentil): OR, efectos marginales (AME) y diferencia de riesgos con efectos fijos (DR-EF).

	IC95_inf	mediana	IC95_sup
OR_R0	3.2508	3.3824	3.5195
OR_R1	1.8953	2.1110	2.3638
cociente_OR	1.4211	1.6018	1.8024
cociente_OR_ponderado	1.4180	1.5977	1.7950
AME_R0	0.0514	0.0535	0.0555
AME_R1	0.0272	0.0324	0.0378
cociente_AME	1.4061	1.6525	1.9778

Tabla 5: Bootstrap por búsqueda (IC 95 % percentil): OR, efectos marginales (AME) y diferencia de riesgos con efectos fijos (DR-EF).

	IC95_inf	mediana	IC95_sup
diferencia_AME	0.0152	0.0210	0.0269
cociente_AME_ponderado	1.4478	1.7011	2.0337
DR_EF_R0	0.0801	0.0826	0.0852
DR_EF_R1	0.0410	0.0476	0.0548
diferencia_DR_EF	0.0277	0.0350	0.0423
cociente_DR_EF	1.5056	1.7351	2.0143

7.5. El clic: paso obligatorio del embudo

Reservar implica hacer clic, así que la identidad exacta $\mathrm{RR}_Y = \mathrm{RR}_{\text{clic}} \times \mathrm{RR}_{\text{conversión|clic}}$ descompone el efecto. Con orden aleatorio: - $\mathrm{RR}_{\text{clic}}$ = 2,96 [2,874; 3,058]; - $\mathrm{RR}_{\text{conversión|clic}}$ = 1,30, que es descriptivo, porque condiciona en un colisionador; - el 80 % del efecto en escala log opera a través de más clics.

"Ajustar por el clic" anula el efecto casi por construcción, así que no es un hallazgo sustantivo de mediación.

7.6. Trampas de selección y del colisionador

Tabla 6: Trampas: ajustar por el mediador y condicionar en colisionadores.

	Δp	IC95	p
efecto total (ajuste Z)	0.0778	[0.0753, 0.0803]	$p < 10^{-300}$
ajustando además por el clic (M)	0.0042	[0.0031, 0.0052]	p = 9,87e-16
solo hoteles clickeados (condicionar en M)	0.1150	[0.0452, 0.1847]	p = 0,001

- **Colisionador natural (selección del dataset):** en la simulación con verdad conocida, el OR intra-búsqueda se recupera con y sin el filtro, mientras que la diferencia absoluta se infla.
- **Colisionador simulado C ($T \to C \leftarrow Y$):**
  - En una simulación con verdad conocida, condicionar en C induce Berkson y llega a invertir el signo del efecto.
  - Sobre los datos reales con orden aleatorio, el sesgo es menor: la Δp ingenua sube un 29 %, con IC superpuestos.
  - La magnitud depende del mecanismo, así que la única regla segura es no condicionar (notebook, 4.5).

7.7. Refutaciones

Tabla 7: Refutaciones de DoWhy sobre la regresión backdoor (orden del algoritmo).

	ATE original	ATE refutado	p	pasa
Causa común aleatoria	0.09611	0.09611	0.484834	True
Placebo (T permutado)	0.09611	-0.00017	0.41635	True
Subconjunto 80 %	0.09611	0.096198	0.442672	True

Las refutaciones de DoWhy evalúan la **estabilidad** de la estimación ante perturbaciones. No detectan la confusión por U: esa la revela el benchmark con orden aleatorio, que es la refutación más exigente del trabajo.

7.8. Double Machine Learning y CATE

`LinearDML` con Random Forest como modelos de ruido estima un ATE de 0,0833 (IC 95 % [0,0788; 0,0877]) con el orden del algoritmo, y de 0,0073 con orden aleatorio. Relativos a sus tasas base, los cocientes son 4,12 y 2,01.

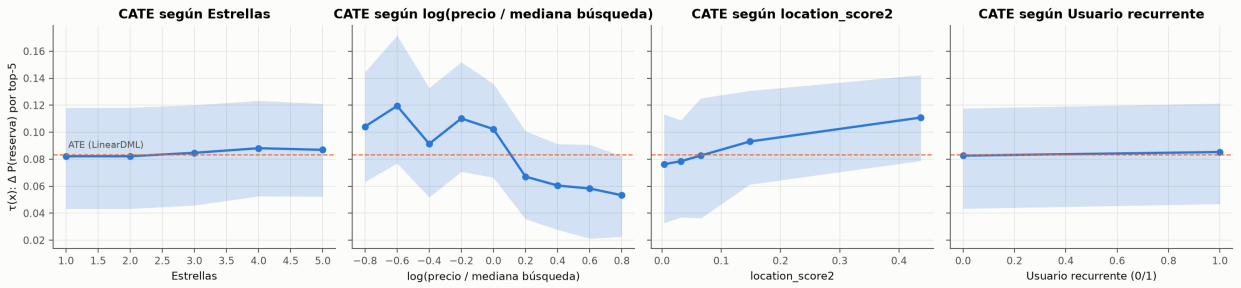


Figura 7: CATE del top-5 (Causal Forest DML, orden del algoritmo) según estrellas, precio relativo, ubicación y usuario recurrente.

8. Traducción a decisiones de negocio

Tabla 8: Escenarios de valuación del slot (por 1.000 exposiciones en el top-5; búsquedas un clic).

	Δp por exposición	gasto por reserva (USD)	desplazamiento de otra reserva	reservas incremen
conservador	0.0055	223.2700	0.5	2.7500
central	0.0064	223.2700	0.0	6.4412
optimista	0.0105	383.4864	0.0	10.5424

- **Valuación del slot: un rango con supuestos explícitos** (Tabla 8). Cada 1.000 exposiciones en el top-5 valen entre 614 y 4.043 USD de gasto incremental, según el efecto supuesto, el gasto por reserva y cuánto de la reserva ganada se le quita a otro hotel de la lista. Vale solo para búsquedas con al menos un clic, y la escala absoluta depende de la selección del dataset: sirve para ordenar decisiones, no para presupuestar.
- **No pagar el sesgo.** Una valuación basada en datos del algoritmo, aun ajustada, sobrestima el OR del slot en 60 %. Cobrar o asignar slots premium con esa cifra sobrevalúa el inventario.
- **Dónde poner el slot.** El CATE (Figura 7) indica los perfiles con mayor retorno incremental: ahí la exposición agrega ventas en lugar de reasignarlas.
- **Limitación operativa.** Los resultados valen para búsquedas con al menos un clic. El efecto sobre el tráfico total no está identificado.

9. Limitaciones

- **Aleatorización imperfecta:** con R = 1 queda una asociación residual posición–atributos; se declara y se ajusta, sin forzar una explicación.

- **Selección del dataset** sobre el clic y, en R = 0, sobre la compra: solo la escala relativa intra-búsqueda es comparable entre estratos.
- **SUTVA:** los slots son de suma cero; el estimando es "efecto dada la competencia de la lista".
- **Confidencialidad:** los resultados publicados podrían considerarse "model parameters" según las reglas de Kaggle. Es un riesgo asumido y documentado.

10. Reproducibilidad y gobernanza de la IA

Código modular en `src/tpi/`, `SEED = 42`, dependencias fijadas, tests automáticos (`pytest`) e integración continua. Este trabajo usó **Claude Code** (Anthropic) como asistente. `docs/ia_log.md` registra los prompts, lo producido, quién propuso y quién aprobó cada decisión, y los 32 errores o alucinaciones detectados, con el test que los refuta o previene. Ningún número de este informe se tomó del texto del asistente: todos salen de `models/resultados.json`, que genera el notebook.

Controles de calidad automáticos: - El notebook **se detiene si un estimador no converge**: el logit condicional y de elección (que falla en lugar de devolver un número dudoso) y el modelo de propensión del IPW. - Ningún archivo de datos puede quedar en el repositorio. - Los artefactos públicos no contienen celdas con menos de 10 filas. - Las refutaciones de premisas quedan como tests `xfail` estrictos con su motivo.

La revisión humana de la autora cambió el análisis central: pidió el balance con re-ponderación, la escala de diferencia de riesgos, el bootstrap con 1000 réplicas y la reformulación del clic como paso del embudo. Métodos: Pearl (2009), Sharma y Kiciman (2020), Chernozhukov et al. (2018) y Prentice y Pyke (1979).

Referencias

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, et al. 2018. «Double/Debiased Machine Learning for Treatment and Structural Parameters». *The Econometrics Journal* 21 (1): C1-68. https://doi.org/10.1111/ectj.12097.

Liu, Xudong, Bing Xu, Yuyu Zhang, et al. 2013. *Combination of Diverse Ranking Models for Personalized Expedia Hotel Searches*. https://arxiv.org/abs/1311.7679.

Pearl, Judea. 2009. *Causality: Models, Reasoning, and Inference*. 2.ª ed. Cambridge University Press. https://doi.org/10.1017/CBO9780511803161.

Prentice, R. L., y R. Pyke. 1979. «Logistic Disease Incidence Models and Case-Control Studies». *Biometrika* 66 (3): 403-11. https://doi.org/10.1093/biomet/66.3.403.

Sharma, Amit, y Emre Kiciman. 2020. *DoWhy: An End-to-End Library for Causal Inference*. https://arxiv.org/abs/2011.04216.