¿El top-5 vende, o solo muestra lo que se vendería igual?

Retorno causal de un algoritmo de recomendación · EAyMR 2026 (UCA)

V. López Marsico (Lead) · L. Báez (Backend/ML-Causal) · A. Robiollio (Frontend + QA)

2026-11-18

1 · El problema de negocio

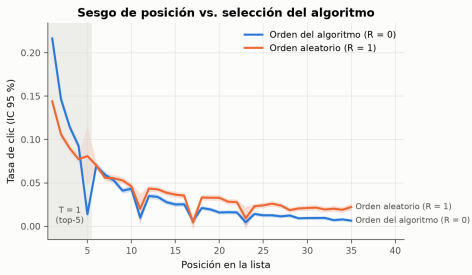
- Unos 25 hoteles por búsqueda; la atención se concentra en los primeros. **Los slots del top son escasos y de suma cero.**
- El recomendador pone arriba hoteles que se venderían igual: ¿el slot **causa** ventas o solo las **predice**?
- La respuesta fija el precio de un slot premium y a quién conviene dárselo.

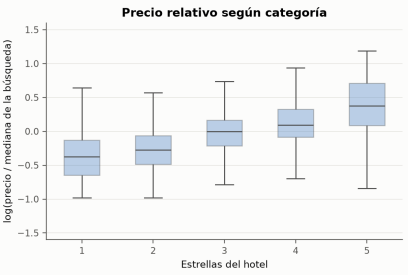
2 · Datos y experimento natural

- Expedia ICDM 2013 (Kaggle): 9.917.530 filas, 399.344 búsquedas; muestra de 30.000 búsquedas completas.
- `random_bool`: una parte de las búsquedas se mostró en **orden aleatorio**, lo que da un benchmark para contrastar el supuesto Backdoor.
- Hallazgos de la auditoría: centinelas, precio en dos escalas, slots fijos 5/11/17/23 fuera del dataset, y un dataset seleccionado sobre el clic (colisionador natural).

3 · Inferencia: el sesgo de posición existe

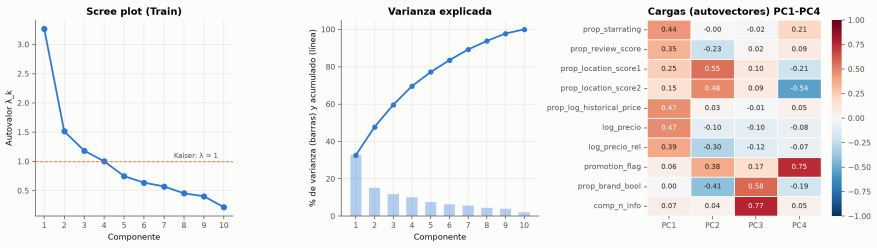
- Con orden aleatorio, la tasa de clic del top-5 es **2,16 veces** la del resto de su lista (t pareado, $d_z = 0{,}306$).
- ANOVA de Welch (Levene rechaza): las estrellas explican $\eta^2 = 0{,}254$ del log precio.
- El gasto por reserva no difiere entre recurrentes y nuevos (no se rechaza H0; efecto mínimo detectable g = 0,090).





4 · Gauss-Markov y PCA

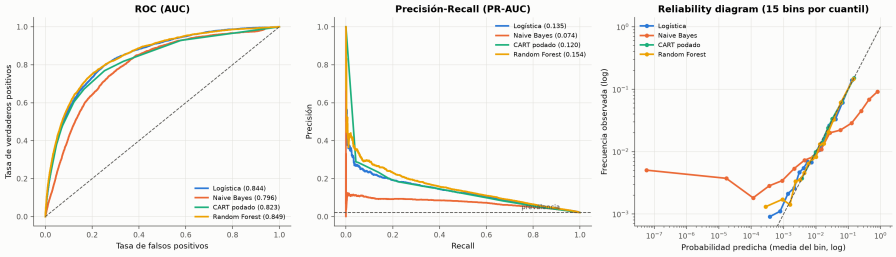
- MCO del log precio: $R^2 = 0{,}604$. Breusch-Pagan rechaza $\rightarrow$ HC3; colas pesadas (curtosis 5,8) $\rightarrow$ Huber de resguardo; Durbin-Watson $= 1{,}95$.
- 746 influyentes ($D > 4/n$), ninguno con $D > 0,5$; más frecuentes cuando la escala del precio es errónea. VIF máx. 2,98.
- PCA solo en Train: PC1 = categoría-precio; PC2 = ubicación y promoción. **Lo reservado se separa por PC2.**



5 · Torneo predictivo

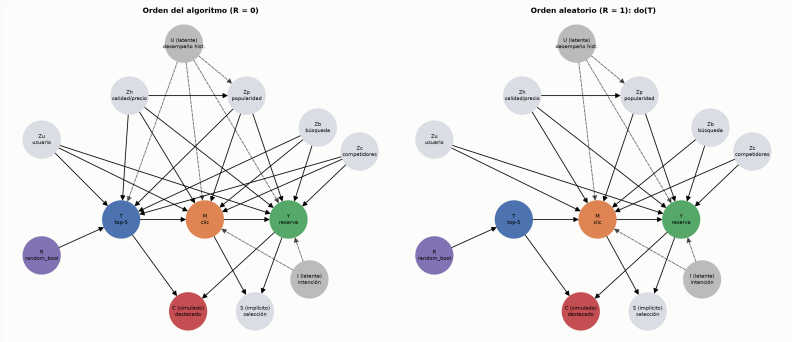
- Logística L1/L2, Naive Bayes, CART podado y Random Forest; CV agrupada por búsqueda; PR-AUC como métrica (prevalencia $\approx 2\,\%$).
- Ganador: **Random Forest**, con PR-AUC 0,154 y ROC-AUC 0,849. El holdout cronológico da 0,146.
- El árbol sin poda memoriza Train (PR-AUC 1,00 contra 0,031 en Test).

6 · Calibración y explicabilidad



- El MDI favorece variables de alta cardinalidad (ρ con la cardinalidad $= 0{,}75$); la permutación en Test lo corrige.
- **La posición es la variable más predictiva**, y en la regla raíz del árbol también.

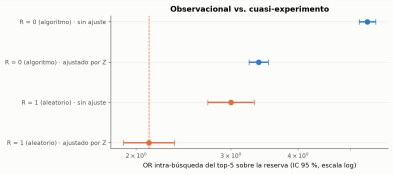
7 · DAG e identificación



- Con el algoritmo, Z bloquea $T \leftarrow Z \rightarrow Y$ pero no $T \leftarrow U \rightarrow Y$ ($U =$ desempeño histórico que usa el ranker). Con orden aleatorio, el conjunto vacío alcanza.

8 · El efecto causal: observacional vs. cuasi-experimento

- OR intra-búsqueda (logit condicional): **benchmark 2,11**, observacional ajustado 3,38, ingenuo 5,38.
- Ajustar por Z explica el 50 % del sesgo. **Los datos son incompatibles con que el ajuste elimine el sesgo**: OR $\times$ 1,60 [1,42; 1,80] y en diferencia de riesgos $\times$ 1,65 [1,41; 1,98] (bootstrap por búsqueda, 1000 réplicas). Se sostiene re-ponderando a la composición de la muestra aleatoria.
- El clic es paso obligatorio del embudo: con orden aleatorio, el 80 % del efecto (escala log) son más clics.



9 · Demo en vivo

- **App Streamlit** (enlace en el README): Diagnóstico + PCA, What-Is (RF compacto, calibración, explicación local), What-If (DAG, ATE, CATE por perfil, semáforo de refutaciones).
- Solo agregados: celdas con menos de 10 filas suprimidas y hojas del modelo con al menos 100 filas.

10 · Conclusiones y bitácora

- **El top-5 sí causa reservas, pero menos de lo que muestran los datos del algoritmo.** Hay que valuar el slot con el benchmark aleatorio y asignarlo donde el CATE es mayor.
- La variable más predictiva **no es una palanca** en la misma magnitud: buena parte es selección.
- Bitácora: 3+ experimentos fallidos documentados y 32 errores de IA detectados, con su test.
- Limitaciones: aleatorización imperfecta, selección sobre el clic, SUTVA y riesgo de licencia declarado.